Chap 3 不确定性知识系统

3.6 概率推理

贝叶斯网络：

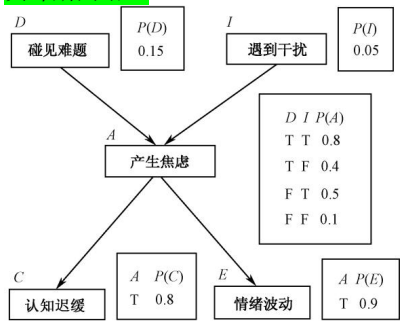

例：若假设已经产生了焦虑情绪，但实际上并未碰见难题，也未遇到干扰，请计算认知迟缓和情绪波动的概率。

答：令相应变量的取值分别为：

a, ¬d, ¬i, c, e

其中，无否定符号表示变量取值为 True，有否定符号表示变量取值为 False，则按贝叶斯网络的联合概率分布表示

$$P(x_1,x_2,\ldots,x_n)=\prod_{i=1}^{n}P(x_i\mid par(X_i))$$

P(c∧e∧a∧¬d∧¬i)

= P(c|a)P(e|a)P(a¬d¬i)P(¬d)P(¬i)

=0.8×0.9×0.1×0.85×0.95

=0.05814

附：可能用到的公式

P(a|b,c)=P(b,c|a)*P(a)/P(b,c)

P(a)=P(a|b,e)*P(b)P(e)+P(a|¬b,e)*P(¬b)P(e)+P(a|b,¬e)*P(b)P(¬e)+P(a|¬b,¬e)*P(¬b)P(¬e)

精确推理：

$$P(d\mid c,e)=\alpha\sum_I\sum_A P(d,I,A,c,e)$$
$$=\alpha\sum_I\sum_A P(d)P(I)P(A\mid d,I)P(c\mid A)P(e\mid A)$$
$$=\alpha P(d)\sum_I P(I)\sum_A P(A\mid d,I)P(c\mid A)P(e\mid A)$$

取 α = 1/(0.047+0.088) = 1/0.135，因此有 P(D|c, e) = α (0.047, 0.088) = (0.348, 0.652)，即在“认知迟缓”和“情绪波动”都发生时，“碰见难题”的概率是 P(d|c, e) = 0.348，不是因为“碰见难题”的概率是 P(¬d|c, e) = 0.652。

近似推理：

P(e|m,¬u)=P(e,m,¬u)/P(m,¬u)

=P(e)P(m|e)P(¬u|e)/[P(e)P(m|e)P(¬u|e)+P(¬e)P(m|¬e)P(¬u|¬e)]

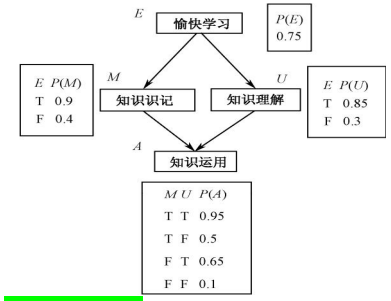

3.4 证据推理

信任函数：

$$Bel(A)=\sum_{s_i\in A}m(\{s_i\})$$

$$Bel(\Omega)=\sum_{B\subseteq\Omega}m(B)=\sum_{i=1}^{n}m(\{s_i\})+m(\Omega)=1$$

似然函数：

$$Pl(A)=1-Bel(\neg A)=1-\sum_{s_i\in\neg A}m(\{s_i\})=1-[\sum_{i=1}m(\{s_i\})-\sum_{s_i\in A}m(\{s_i\})]$$
$$=1-[1-m(\Omega)-Bel(A)]$$
$$=m(\Omega)+Bel(A)$$
$$Pl(\Omega)=1-Bel(\neg\Omega)=1-Bel(\Phi)=1$$

不确定性证据的确定性 CER(A)

AND:CER(E)=min{CER(E1).CER(En)}

OR:CER(E)=max{CER(E1)...CER(En)}

设有知识 IF E THEN H={h1, h2, ⋯ , hn} CF={c1, c2, ⋯ , cn}则求结论 H 的确定性 CER(H)的方法如下：

$$m(\{h_1\},\{h_2\},\ldots,\{h_n\})=(CER(E)\times c_1,CER(E)\times c_2,\ ,CER(E)\times c_n)$$

$$m(\Omega)=1-\sum_{i=1}^{n}CRE(E)\times c_i$$

如果有两条或多条知识支持同一结论H，例：

IF E_1 THEN $H=\{h_1,h_2,\ldots,h_n\}$ $CF=\{c_{11},c_{12},\ldots,c_{1n}\}$

IF E_2 THEN $H=\{h_1,h_2,\ldots,h_n\}$ $CF=\{c_{21},c_{22},\ldots,c_{2n}\}$

则按正交和求CER(H)，即先求出：

$m_1=m_1(\{h_1\},\{h_2\},\ldots,\{h_n\})$

$m_2=m_2(\{h_1\},\{h_2\},\ldots,\{h_n\})$

然后再用公式 $m=m_1\oplus m_2$ 求m_1和m_2的正交和，最后求得H的m。

$$Bel(H)=\sum_{i=1}^{n}m(\{h_i\})$$

$$Pl(H)=1-Bel(\neg H)$$

$$f(H)=Bel(H)+\frac{|H|}{|\Omega|}\times[Pl(H)-Bel(H)]=Bel(H)+\frac{|H|}{|\Omega|}\times m(\Omega)$$

CER(H)=MD(H|E') ×f(H)

$$MD(H\mid E')=\begin{cases}1 & \text{如果H所要求的证据都已出现在E'中}\\ 0 & \text{否则}\end{cases}$$

例3.8 设有如下规则：

r_1: IF E_1 AND E_2 THEN $A=\{a_1,a_2\}$ CF={0.3, 0.5}

r_2: IF E_3 THEN $H=\{h_1,h_2\}$ CF={0.4, 0.2}

r_3: IF A THEN $H=\{h_1,h_2\}$ CF={0.1, 0.5}

已知 CER(E1)=0.8 CER(E2)=0.6 CER(E3)=0.9,并假定Ω中的元素个数|Ω|=10 求：CER(H)=?

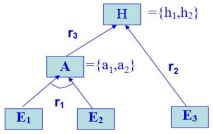

(1) 求 CER(A)

CER(E1 AND E2)=min{CER(E1), CER(E2)}=min{0.8, 0.6} = 0.6

m({a1}, {a2})={0.6×0.3, 0.6×0.5} = {0.18, 0.3} Bel(A)=m({a1})+m({a2})=0.48

Pl(A)=1-Bel(¬A)=1-0=1

f(A)=Bel(A)+|A|/|Ω|•[Pl(A)-Bel(A)]=0.584

CER(A)=MD(A|E')×f(A)=0.584

(2) 求 CER(H)

m1({h1}, {h2})={CER(E3)×0.4, CER(E3)×0.2}={0.36, 0.18}

m1(Ω)=1-[m1({h1})+m1({h2})]=1-[0.36+0.18]=0.46

m2({h1}, {h2})={CER(A)×0.1, CER(A)×0.5}={0.06, 0.29}

m2(Ω)=1-[m2({h1})+m2({h2})]=1-[0.06+0.29]=0.65

求正交和 m=m1⊕m2:

K=m1(Ω)×m2(Ω)+m1({h1})×m2({h1})+m1({h1})×m2(Ω)+m1(Ω)×m2({h1})+m1({h2})×m2({h2})+m1({h2})×m2(Ω)+m1(Ω)×m2({h2})=0.88

m(h1)=1/K×[m1({h1})×m2({h1})+m1({h1})×m2(Ω)+m1(Ω)×m2({h1})]=0.32

m(h2)=1/K×[m1({h2})×m2({h2})+m1({h2})×m2(Ω)+m1(Ω)×m2({h2}]=0.34

故有：m(Ω)=1-[m({h1})+m({h2})]=1-[0.32+0.34] = 0.34

Bel(H)=m({h1})+m({h2}) = 0.66 Pl(H)=m(Ω)+Bel(H)=1

$$f(H)=Bel(H)+\frac{|H|}{|\Omega|}\bullet[Pl(H)-Bel(H)]$$

∴CER(H)=MD(H|E')×f(H)=0.73

3.5 模糊推理

定义:设F、G分别是U上的两个模糊集，则F∪G、F∩G分别称为F与G的并集、交集，它们的隶属函数分别为：

$$F\cup G:\mu_{F\cup G}(u)=\max_{u\in U}\{\mu_F(u),\mu_G(u)\}$$

$$F\cap G:\mu_{F\cap G}(u)=\min_{u\in U}\{\mu_F(u),\mu_G(u)\}$$

设F为U上的模糊集，称¬F为F的补集，其隶属函数为：

$$\neg F:\mu_{\neg F}(u)=1-\mu_F(u)$$

模糊集的运算

例:设 U={1,2,3}，F 和 G 分别是 U 上的两个模糊集（小，大），且 F=1/1+0.6/2+0.1/3 G=0.1/1+0.6/2+1/3，则

F∪G=(1∨0.1)/1+(0.6∨0.6)/2+(0.1∨1)/3=1/1+0.6/2+1/3 F∩G=(1∧0.1)/1+(0.6∧0.6)/2+(0.1∧1)/3=0.1/1+0.6/2+0.1/3

¬F=(1-1)/1+(1-0.6)/2+(1-0.1)/3=0.4/2+0.9/3

定义：设 R1 与 R2 分别是 U×V 与 V×W 上的两个模糊关系，则 R1 与 R2 的合成是从 U 到 W 的一个模糊关系，记为 R1oR2。

其隶属函数为

$$\mu_{R_1\circ R_2}(u,w)=\vee\{\mu_{R_1}(u,v)\wedge\mu_{R_2}(v,w)\}$$

例：设有以下两个模糊关系

$$R_1=\begin{bmatrix}0.4&0.5&0.6\\0.8&0.3&0.7\end{bmatrix}\quad R_2=\begin{bmatrix}0.7&0.9\\0.2&0.8\\0.5&0.3\end{bmatrix}$$

$$R=R_1\circ R_2=\begin{bmatrix}0.5&0.5\\0.7&0.8\end{bmatrix}$$

其方法是把 R1 的第 i 行元素分别与 R2 的第 j 列的对应元素相比较，两个数中取最小者，然后再在所得的一组最小数中取最大的一个，并以此数作为 R1oR2 的元素 R(i,j)。

模糊变换：

例3.14 设F=(1, 0.6, 0.2)

$$R=\begin{bmatrix}1&0.5&0&0\\0.5&1&0.5&0\\0&0.5&1&0.5\end{bmatrix}$$

则G= FoR={(1∧1)∨(0.6∧0.5)∨(0.2∧0),
(1∧0.5)∨(0.6∧1)∨(0.2∧0.5),
(1∧0)∨(0.6∧0.5)∨(0.2∧1),
(1∧0)∨(0.6∧0)∨(0.2∧0.5)}
={1, 0.6, 0.5, 0.2}

模糊关系

$$R_m=\int_{U\times V}(\mu_F(u)\wedge\mu_G(v))\vee(1-\mu_F(u))/(u,v)$$

$$R_c=\int_{U\times V}(\mu_F(u)\wedge\mu_G(v))/(u,v)$$

$$R_g=\int_{U\times V}(\mu_F(u)\to\mu_G(v))/(u,v$$

$$\mu_F(u)\to\mu_G(v)=\begin{cases}1 & \text{当}\mu_F(u)\le\mu_G(v)\text{时}\\ \mu_G(v) & \text{当}\mu_F(u)>\mu_G(v)\text{时}\end{cases}$$

模糊假言三段论：例 U=W=V={1,2,3},E=1/1+0.6/2+0.2/3,F=0.8/1+0.5/2+0.1/3, G=0.2/1+0.6/2+1/3。按 Rg 求 E×F×G 上的关系 R。

解：先求 E×F 上的关系 R1

$$R_1=\begin{bmatrix}0.8&0.5&0.1\\1&0.5&0.1\\1&1&0.1\end{bmatrix}$$

再求 F×G 上的关系 R

$$R_2=\begin{bmatrix}0.2&0.6&1\\0.2&1&1\\1&1&1\end{bmatrix}$$

最后求 E×F×G 上的关系 R

$$R=R_1\circ R_2=\begin{bmatrix}0.2&0.6&0.8\\0.2&0.6&1\\0.2&1&1\end{bmatrix}$$

Chap 4 搜索

4.2 代价树（广度优先）

代价树的代价：用 g(n)表示从初始节点 S0 到节点 n 的代价，用 c(n, n1)表示从父节点 n 到其子节点 n1 的代价。这样，对节点 n1 的代价有：

g(n1)=g(n)+c(n, n1)

例 1:列出图中树的访问序列以满足下列广度搜索策略，并写出搜索过程中的 OPEN 表和 CLOSE 表。

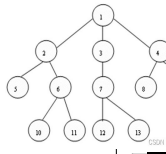

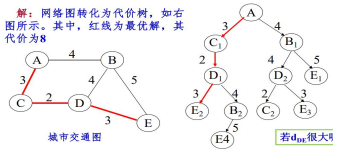

open	close
1	
2,3,4	1
3,4,5,6	1,2
4,5,6,7	1,2,3
5,6,7,8,9	1,2,3,4
6,7,8,9	1,2,3,4,5
7,8,9,10,11	1,2,3,4,5,6
8,9,10,11,12,13	1,2,3,4,5,6,7
9,10,11,12,13	1,2,3,4,5,6,7,8
10,11,12,13	1,2,3,4,5,6,7,8,9
11,12,13	1,2,3,4,5,6,7,8,9,10
12,13	1,2,3,4,5,6,7,8,9,10,11
13	1,2,3,4,5,6,7,8,9,10,11,12

4.3 解树的代价与希望树

1.若 n 为终止节点，则其代价 h(n)=0
2.若 n 为或节点,且子节点为 n1,n2,…,nk,则 n 的代价为 h(n)=min$_{1\le i\le k}${c(n,n$_i$)+h(n$_i$)}，式中，c(n, ni)是节点 n 到其子节点 ni 的边代价。
3.若 n 为与节点,且子节点为 n1, n2, …, nk，则 n 的代价可用和代价法或最大代价法计算。
若用和代价法，则其计算公式为

$$h(n)=\sum_{i=1}^{k}[c(n,n_i)+h(n_i)]$$

若用最大代价法，则其计算公式为

$$h(n)=\max_{1\le i\le k}\{c(n,n_i)+h(n_i)\}$$

4. 若 n 是端节点，但不是终止节点，则 n 不可扩展，其代价为 h(n) = ∞. 根节点的代价即为解树的代价。例：

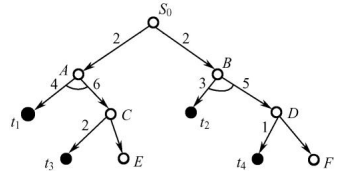

先计算左边的解树：
按和代价：h(S0) = 2+4+6+2 = 14
按最大代价：h(S0) = 8+2 = 10
再计算右边的解树：
按和代价：h(S0) = 1+5+3+2 = 11
按最大代价：h(S0) = 6+2 = 8

A*算法

修道士和野人问题：用 m 表示左岸的修道士人数，c 表示左岸的野人数，b 表示左岸的船数，用三元组(m, c, b)表示问题的状态。
对 A*算法，首先需要确定估价函数。设深度 g(n)=d(n)，h(n)=m+c-2b，则有 f(n)=g(n)+h(n)=d(n)+m+c-2b

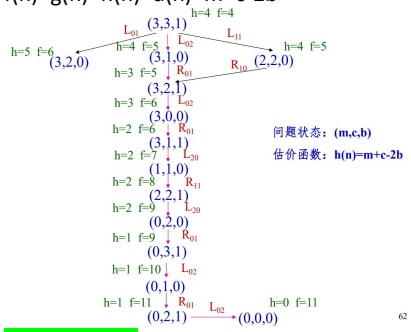

4.4 α - β 剪枝

MAX 节点（或节点）的α值为当前子节点的最大倒推值；
MIN 节点（与节点）的β值为当前子节点的最小倒推值；

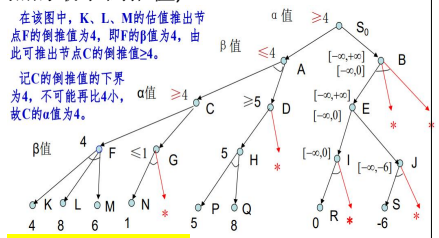

在该图中，K、L、M的估值推出节点F的倒推值为4，即F的β值为4，由此可推出节点C的倒推值≥4。
记C的倒推值的下界为4，不可能再比4小，故C的α值为4。

Chap 5 机器学习

5.1 基本要求
(1)具有适当的学习环境。
(2) 具有一定的学习能力。
(3) 能够运用所学知识求解问题 学以致用。
(4) 通过学习提高自身性能。

5.4 决策树（ID3 算法）

信息熵的定义

$$E(S)=-P(y_1)\log P(y_1)-P(y_2)\log P(y_2)-\cdots-P(y_r)\log P(y_r)$$
$$=-\sum_{j=1}^{k}P(y_j)\log P(y_j)$$

加权信息熵：$\mathbf{E(S,x_i)=\sum_{t=1}^{r}\frac{|S_t|}{|S|}\times E(S_t)}$
信息增益：

$$\mathbf{G(S,x_i)=E(S)-E(S,x_i)=E(S)-\sum_{t=1}^{r}\frac{|S_t|}{|S|}\times E(S_t)}$$

条件熵 H(D|A) $=\sum_{i=1}^{n}\frac{|D_i|}{|D|}H(D_i)$

1.计算根节点的信息熵和加权信息熵

序号	属性值			决策方案
	x_1（层次）	x_2（专业）	x_3（学否）	y_j
1	1	1	1	y_3
2	1	1	2	y_1
3	1	2	1	y_3
4	1	2	2	y_2
5	2	1	1	y_3
6	2	1	2	y_2
7	2	2	1	y_3
8	2	2	2	y_3

$$\mathbf{E(S,X)=-\sum_{i=1}^{3}P(y_i)log_2P(y_i)}$$

2.计算 x1、x2、x3 节点的信息熵和加权信息熵，还有信息增益，并进行比较，选择最大的。
即有根节点的信息熵

$$\mathbf{E(S,X)=-\frac{1}{8}\times log_2\left(\frac{1}{8}\right)-\frac{2}{8}\times log_2\times\left(\frac{2}{8}\right)-\frac{5}{8}\times log_2\left(\frac{5}{8}\right)}$$

然后再计算根节点(S,X)关于每个属性的加权信息熵

$$\mathbf{E((S,X),x_i)=\sum_{i}\frac{|S_t|}{|S|}\cdot E(S_t,X)}$$

当 x1=1 时，t=1，有 S1={1,2,3,4}
当 x1=2 时，t=2，有 S2={5,6,7,8}

$$E(S_1,X)=-P_{S_1}(y_1)\log_2P_{S_1}(y_1)$$
$$-P_{S_1}(y_1)\log_2P_{S_1}(y_2)-P_{S_1}(y_3)\log_2P_{S_1}(y_3)$$
$$=-\frac{1}{4}\times\log\frac{1}{4}-\frac{1}{4}\times\log\frac{1}{4}-\frac{2}{4}\times\log\frac{2}{4}$$
$$=1.5$$

$$E(S_2,X)=-P_{S_2}(y_1)\log_2P_{S_2}(y_1)$$
$$-P_{S_2}(y_1)\log_2P_{S_2}(y_2)-P_{S_2}(y_3)\log_2P_{S_2}(y_3)$$
$$=0-\frac{1}{4}\times\log\frac{1}{4}-\frac{3}{4}\times\log\frac{3}{4}$$
$$=0.8113$$

$$E((S,X),x_1)=\frac{|S_1|}{|S|}\times E(S_1,X)+\frac{|S_2|}{|S|}\times E(S_2,X)$$
$$=\frac{4}{8}\times1.5+\frac{4}{8}\times0.8113$$
$$=1.1557$$

同样可以求得

$$E((S,X),x_2)=1.1557$$
$$E((S,X),x_3)=0.75$$

G((S,X), x_1)= E(S,X)–E((S,X), x_1) = 1.2988 – 1.1557 = 0.1431
G((S,X), x_2)= E(S ,X)–E((S,X), x_2) = 1.2988 – 1.1557 = 0.1431
G((S,X), x_3)= E(S,X)–E((S,X), x_3) = 1.2988 – 0.75 = 0.5488
显然，x_3的信息增益最大，因此应先选择x_3对根节点进行扩展。
取 x3=1、2,生成根节点的左右分支 S1'和 S2',从属性集中删除 x3.
3.进行下一轮扩展.重新计算信息熵和信息增益。

$$\mathbf{E(S_2',X_1)=-\frac{1}{4}log_2\frac{1}{4}-\frac{1}{4}log_2\frac{1}{4}-\frac{2}{4}log_2\frac{2}{4}=1.5}$$

当取x_1=1时，有t=1，设所得样本子集为S'_{21}，则$S'_{21}=\{2,4\}$，
当取x_1=2时，有t=2，设所得样本子集为S'_{22}，则$S'_{22}=\{6,8\}$，
若取x_1=1，不同类别样本在S_{21}上的概率分别为

$$P_{S'_{21}}(y_1)=\frac{1}{2},\ P_{S'_{21}}(y_2)=\frac{1}{2},\ P_{S'_{21}}(y_3)=0$$

故有节点（S_2'，X_1）关于属性x_1=1的信息熵

$$\mathbf{E(S'_{21},X_1)=-\frac{1}{2}log_2\frac{1}{2}-\frac{1}{2}log_2\frac{1}{2}=1}$$

若取x_1=2，不同类别样本在S'_{22}上的概率分别为

$$P_{S'_{22}}(y_1)=0,\ P_{S'_{22}}(y_2)=\frac{1}{2},\ P_{S'_{22}}(y_3)=\frac{1}{2}$$

故有节点（S_2'，X_1）关于属性x_1=2的信息熵

$$\mathbf{E(S'_{22},X_1)=-\frac{1}{2}log_2\frac{1}{2}-\frac{1}{2}log_2\frac{1}{2}=1}$$

由$\mathbf{E(S'_{21},X_1)}$和$\mathbf{E(S'_{22},X_1)}$可求出x_1的加权信息熵

$$E((S'_2,X_1),x_1)=\frac{|S'_{21}|}{|S'_2|}E(S'_{21},X_1)+\frac{|S'_{22}|}{|S'_2|}E(S'_{22},X_1)=\frac{2}{4}\times1+\frac{2}{4}\times1=1$$

进而求出x_1的信息增益

$$G((S'_2,X_1),x_1)=E(S'_2,X_1)-E((S'_2,X_1),x_1)=1.5-1=0.5$$

然后再考虑属性x_2，对x_2的不同属性值：
当取x_2=1时，有t=1，设所得样本子集为S''_{21}，则$S''_{21}=\{2,6\}$；
当取x_2=2时，有t=2，设所得样本子集为S''_{22}，则$S''_{22}=\{4,8\}$。
其中S''_{21}和S''_{22}中的数字也同样为样本集S中各样本的序号，且有$|S_2|=4$，$|S''_{21}|=|S''_{22}|=2$。
先取x_2=1，不同类别样本在子集S''_{21}上的概率分别为

$$P_{S''_{21}}(y_1)=\frac{1}{2},\quad P_{S''_{21}}(y_2)=\frac{1}{2},\quad P_{S''_{21}}(y_3)=0$$

故有节点（S_2'，X_1）关于属性x_2=1的信息熵

$$E(S''_{21},X_1)=-\frac{1}{2}log_2\frac{1}{2}-\frac{1}{2}log_2\frac{1}{2}=1$$

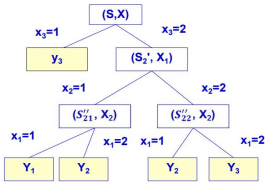

图5.7 最终得到的决策决策树

再取x_2=2，不同类别样本在样本子集S''_{22}上的概率分别为

$$P_{S''_{22}}(y_1)=0,\ P_{S''_{22}}(y_2)=0.5,P_{S''_{22}}(y_3)=0.5$$

故有节点（S_2''，X_1）关于属性x_2=2的信息熵

$$E(S''_{22},X_1)=1$$

由$E(S''_{21},X_1)$和$E(S''_{22},X_1)$可求出x_2的加权信息熵

$$E((S_2',X_1),x_2)=\frac{2}{4}E(S''_{21})+\frac{2}{4}E(S''_{22})=1$$

故有x_2的信息增益

$$G((S_2',X_1),x_2)=E(S_2',X_1)-E((S_2',X_1),x_2)=0.5$$

可见，x_2的信息增益等于x_1的信息增益，先选哪个属性都可以，假设先扩展x_2。
接着执行算法第(5)步，对属性x_2的所有取值分别生成节点（S_2'，X_1）的不同分支节点。当x_2=1时，生成其左子节点；当x_2=2时，生成其右子节点。

5.5 统计学习（可能考概念）
期望风险：统计学习是要根据给定的训练样本,求用联合概率分布函数 P(x, y)表示的输入变量集 x 和输出变量集 y 之间未知的依赖关系，并使期望风险最小。
设有 n 个独立且同分布的训练样本（x1 , y 1）…（xn , yn）在一个函数集{ f(x, w) }中求出一个最优函数 f(x, w0)，使得系统用该函数对依赖关系进行估计时期望风险最小。

$$R(w)=\int L(y,f(x,w))dP(x,y)$$

经验风险：由于概率分布函数 P(x, y)未知，因此无法直接对其进行计算。常用的方法是利用经验风险函数对期望风险进行估计。

$$R_{emp}(w)=\frac{1}{n}\sum_{i=1}^{n}L(y_i,f(x_i,w))$$

期望风险与经验 风险之间以概率（1-η）满足如下量化关系：

$$R(w)\le R_{emp}(w)+\sqrt{\frac{h(\ln(2n/h)+1)-\ln(\eta/4)}{n}}$$

结构风险最小化：同时降低经验风险和置信范围 （即 VC 维），使期望风险最小化。

Chap 6 人工神经网络

6.5.1 卷积神经网络（CNN）
深度卷积神经网络的基本结构通常由三部分组成：第一部分为输入层，第二部分由多个卷积层和池化层交替组合而构成，第三部分由一个全连接层和输出层所构成。

6.6 BP 算法

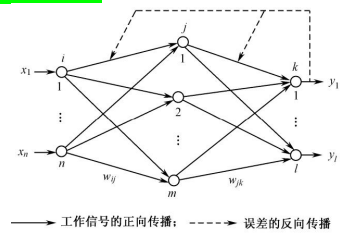

对输入层节点 i，有 Ii=Oi=xi
对隐含层节点 j，有

$$I_j=\sum_{i=1}^{n}w_{ij}O_i=\sum_{i=1}^{n}w_{ij}x_i\qquad(j=1,2,\cdots,m)$$
$$O_j=f(I_j-\theta_j)\qquad(j=1,2,\cdots,m)$$

对输出层节点 k，有

$$I_k=\sum_{j=1}^{m}w_{jk}O_j\qquad(k=1,2,\cdots,l)$$
$$O_k=f(I_k-\theta_k)\qquad(k=1,2,\cdots,l)$$

激发函数 f(x)=1/(1+e^{-x});f'(x)=f(x)[1-f(x)]
一个输入实际输出与期望输出的误差

$$E=\frac{1}{2}\sum_{k=1}^{l}(d_k-y_k)^2$$

，$y_{rk}=O_{rk}$
总体误差公式

$$E_R=\sum_{r=1}^{R}E_r=\frac{1}{2}\sum_{r=1}^{R}\sum_{k=1}^{l}(d_{rk}-y_{rk})^2$$

连接权值的调整公式：
$\Delta w_{jk}(t+1)=w_{jk}(t)+\Delta w_{jk}$
为了使连接权值能沿着 E 的梯度下降的方向逐渐改善，网络逐渐收敛，权值变化量 Δ w_{jk} 的计算公式：$\Delta w_{jk}=-\eta\frac{\partial E}{\partial w_{jk}}$
η 为增益因子，取[0, 1]区间的正数。
求偏导数，令局部梯度为

$$\frac{\partial I_k}{\partial w_{jk}}=\frac{\partial}{\partial w_{jk}}\sum_{j=0}^{m}w_{jk}O_j=O_j\ \delta_k=-\frac{\partial E}{\partial I_k}$$

代入可得，

$$\Delta w_{jk}=-\eta\cdot\frac{\partial E}{\partial w_{jk}}=-\eta\cdot\frac{\partial E}{\partial I_k}\cdot\frac{\partial I_k}{\partial w_{jk}}=\eta\delta_kO_j$$

（1）若节点 k 为输出层节点

$$\delta_k=-\frac{\partial E}{\partial I_k}=-\frac{\partial E}{\partial y_k}\times\frac{\partial y_k}{\partial I_k}$$

= $(d_k-y_k)f'(I_k)$ = $(d_k-y_k)(1-y_k)$
∴$w_{jk}(t+1)$ = $w_{jk}(t)+\triangle w_{jk}$
= $w_{jk}(t)+\eta_k(d_k-y_k)(1-y_k)y_jO_j$
（2）若节点 k 为隐含层节点

$$\delta_j=-\frac{\partial E}{\partial O_j}f'(I_j)$$

$$-\frac{\partial E}{\partial O_j}=-\sum_{k=1}^{l}\frac{\partial E}{\partial I_k}\times\frac{\partial I_k}{\partial O_j}=\sum_{k=1}^{l}\left(-\frac{\partial E}{\partial I_k}\right)\times\frac{\partial}{\partial O_j}\left(\sum_{j=1}^{m}w_{jk}O_j-\theta_k\right)$$
$$=\sum_{k=1}^{l}\left(-\frac{\partial E}{\partial I_k}\right)w_{jk}$$

$$\delta_j=f(I_j)[1-f(I_j)]\sum_{k=1}^{l}\delta_kw_{jk}$$

∴$w_{ij}(t+1)=w_{ij}(t)+\triangle w_{ij}$=

$$w_{ij}(t)+\eta O_j(1-O_j)\left(\sum_{k=1}^{l}\delta_kw_{jk}\right)x_i$$