# 信息、计算与控制

Fundamentals of Information, Computation and Control

**主讲：叶 志**

**浙江大学信电学院**

# 讲义信息

- 助教信息：
  - -黄天凤
  - -QQ：1419764256
  - -微电子楼303

# 第三讲　信息感知与压缩

# 信息感知概述

## ★ 全信息的获取

- ✧信息的**感**、**传**、**知**、**用**
- ✧信息获取的本质

- ✧全信息（认知论信息）

同时考虑事物运动状态及其变化方式的外在形式、内在含义和效用价值的认识论层次信息

  - 语法信息：外在形式
  - 语义信息：内在含义
  - 语用信息：对于主体目标而言的效用价值

# 信息感知概述

## ✧语法信息的获取

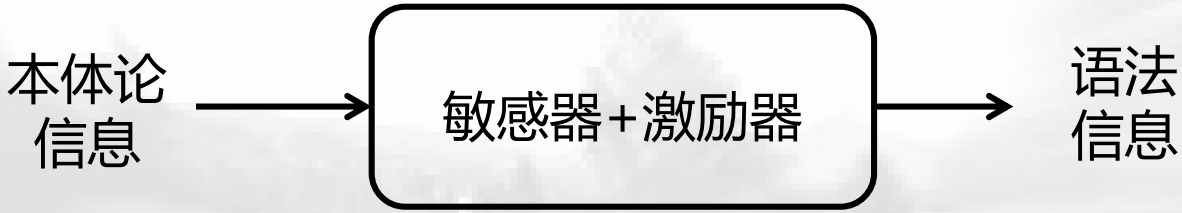


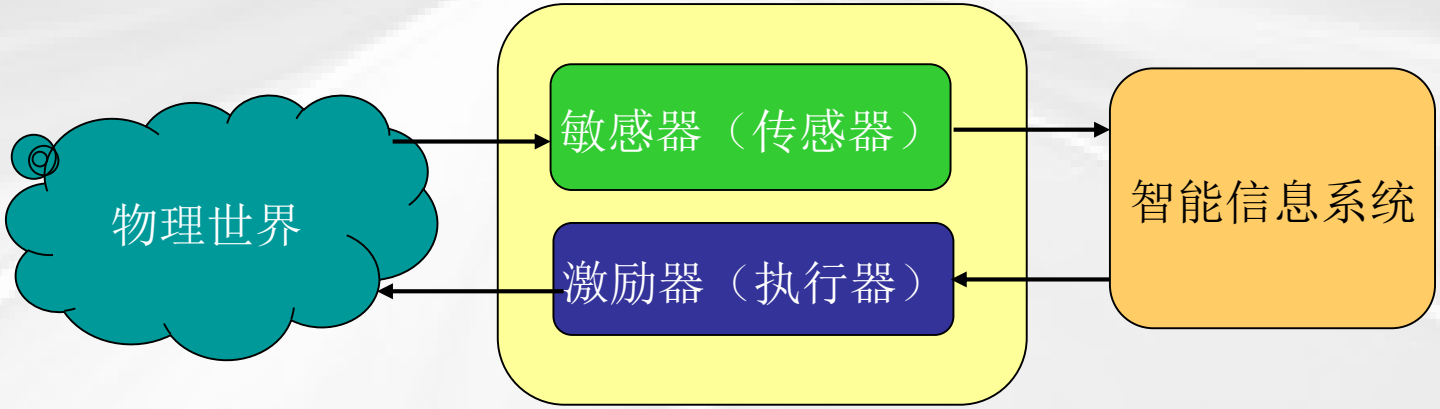

# 信息感知的机制和条件

- 基本机制：利用特定的物理效应对事物的运动变化产生响应。
  - 机械、物理（声、热、电、磁、光）、生化……
  - 热敏效应、电磁感应、光电效应、超导效应……
- 基本条件：
  - 具有一定的敏感域（感受域）
  - 具有一定的敏感度（灵敏度）
  - 具有一定的保真度（可信度）

# 信息获取的输出形式



- 信息载体：电信号、光信号、声信号…
- 数学和物理形式
  - 模拟（连续）信号
  - 离散（数字）信号（序列）
  - 标量信号和矢量信号
- 统计特征
  - 单事件触发型（单变量）
  - 周期触发型（周期序列）
  - 连续随机触发型（平稳源、非平稳源；有记忆性和无记忆性）

# 典型传感器

温度传感器

光敏感器

磁敏感器

超声传感器

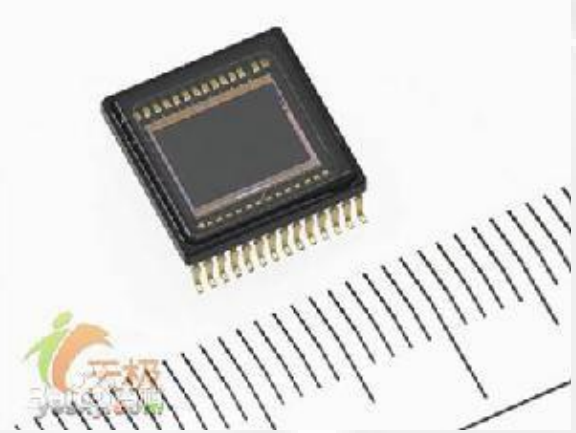

电荷耦合图像传感器

CO2敏感器

# 多传感器融合

- 单传感器的局限
  - 敏感域不广
  - 敏感度不强
  - 分辨率不高

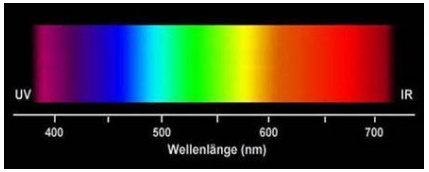


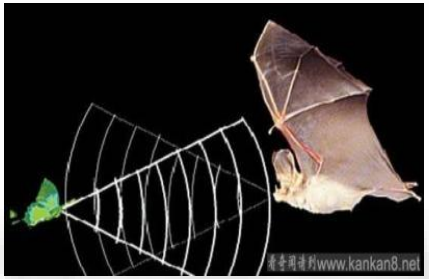

- 多传感器融合

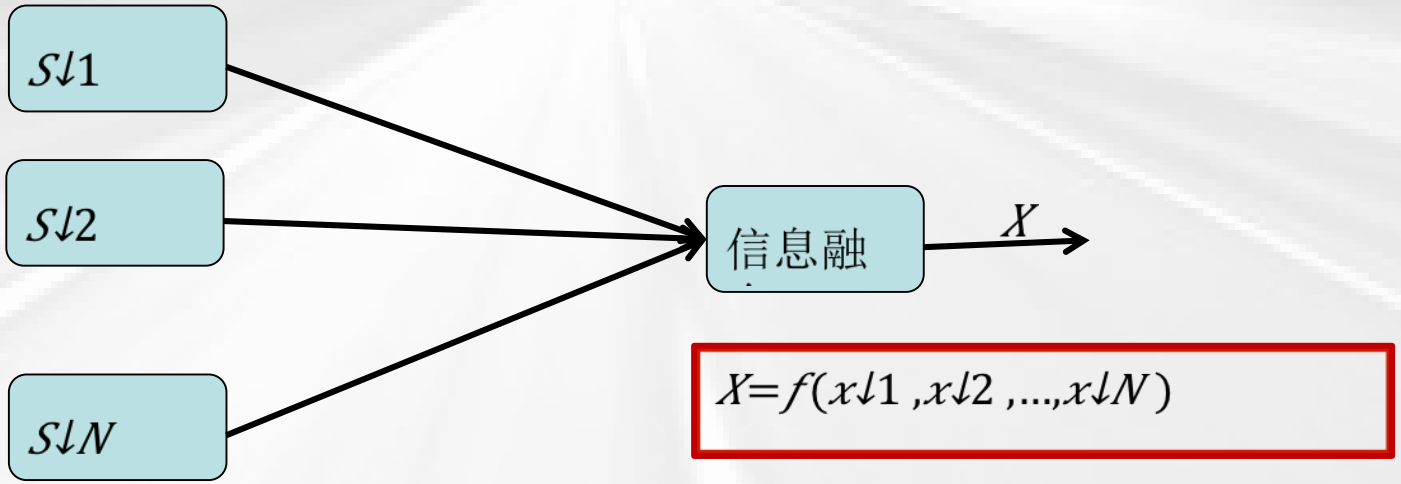


$$X=f(x_1, x_2, \ldots, x_N)$$

# 传感网络

- 多传感器分布式融合
- 感知与传输一体化协同
- 适合于动态大范围的分布式感知
- 物联网的神经末梢

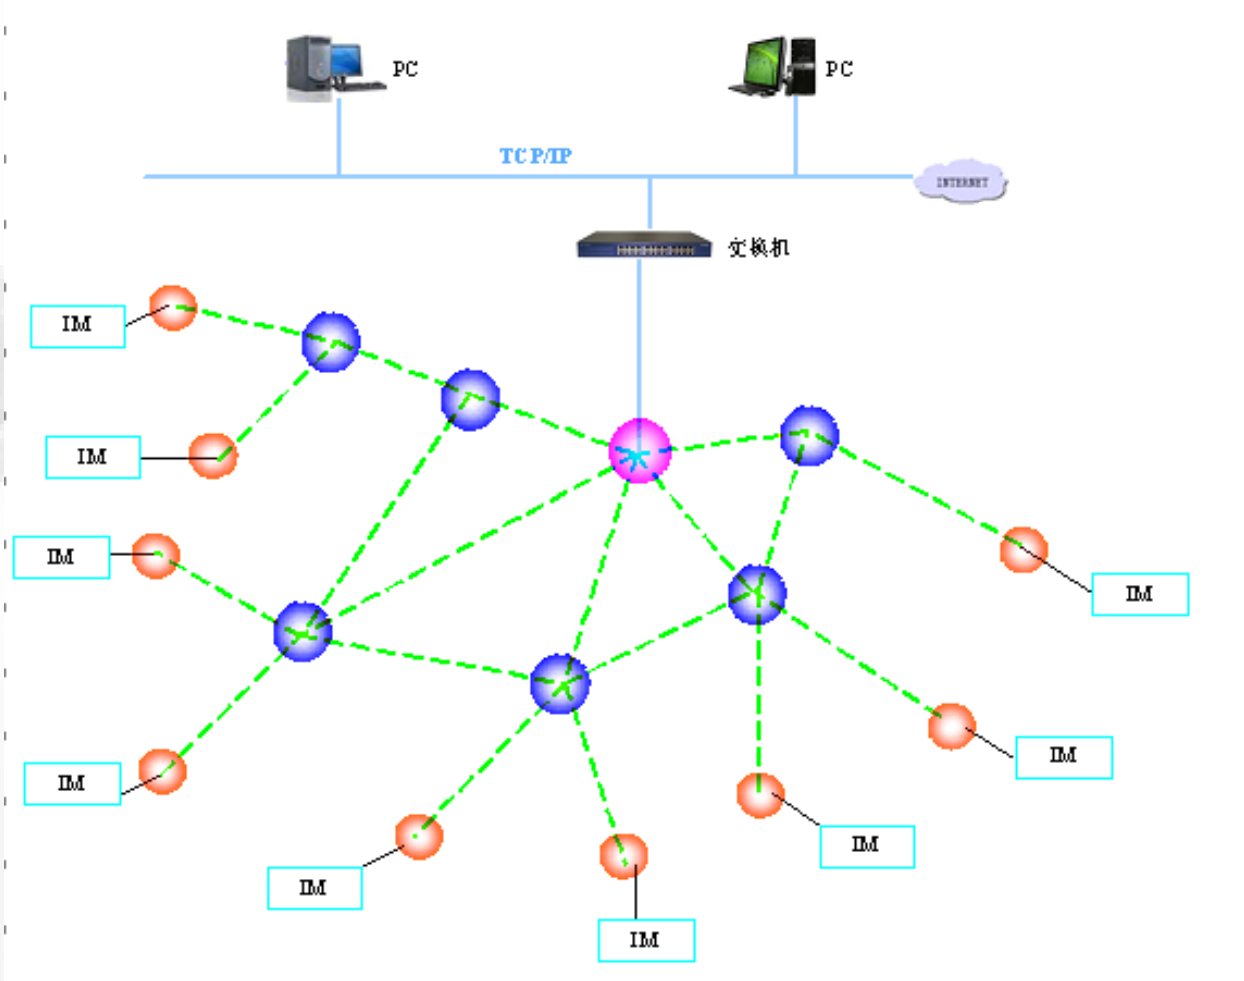

# 信息获取的选择性与关注度
## ——语法信息的识别

- 识别方法
  - 统计学方法：统计检测与估计问题
  - 语言学方法：上下文推理
  - 神经网络方法：学习推理和预测

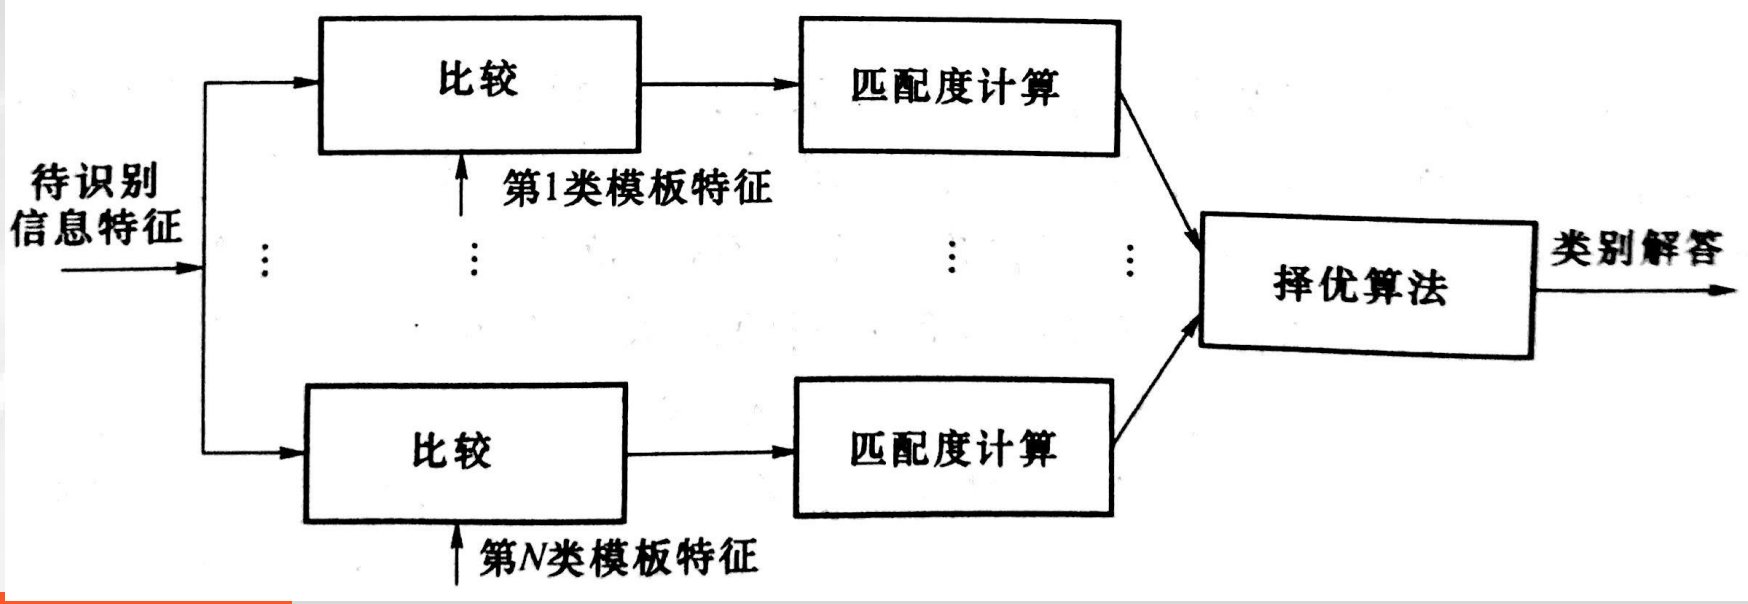

# ★ 全信息的获取

## ⊙第一类信息转换：

– 第一类：本体论信息到全信息的转换；第二类：全信息到知识、策略和行为的转换原理。

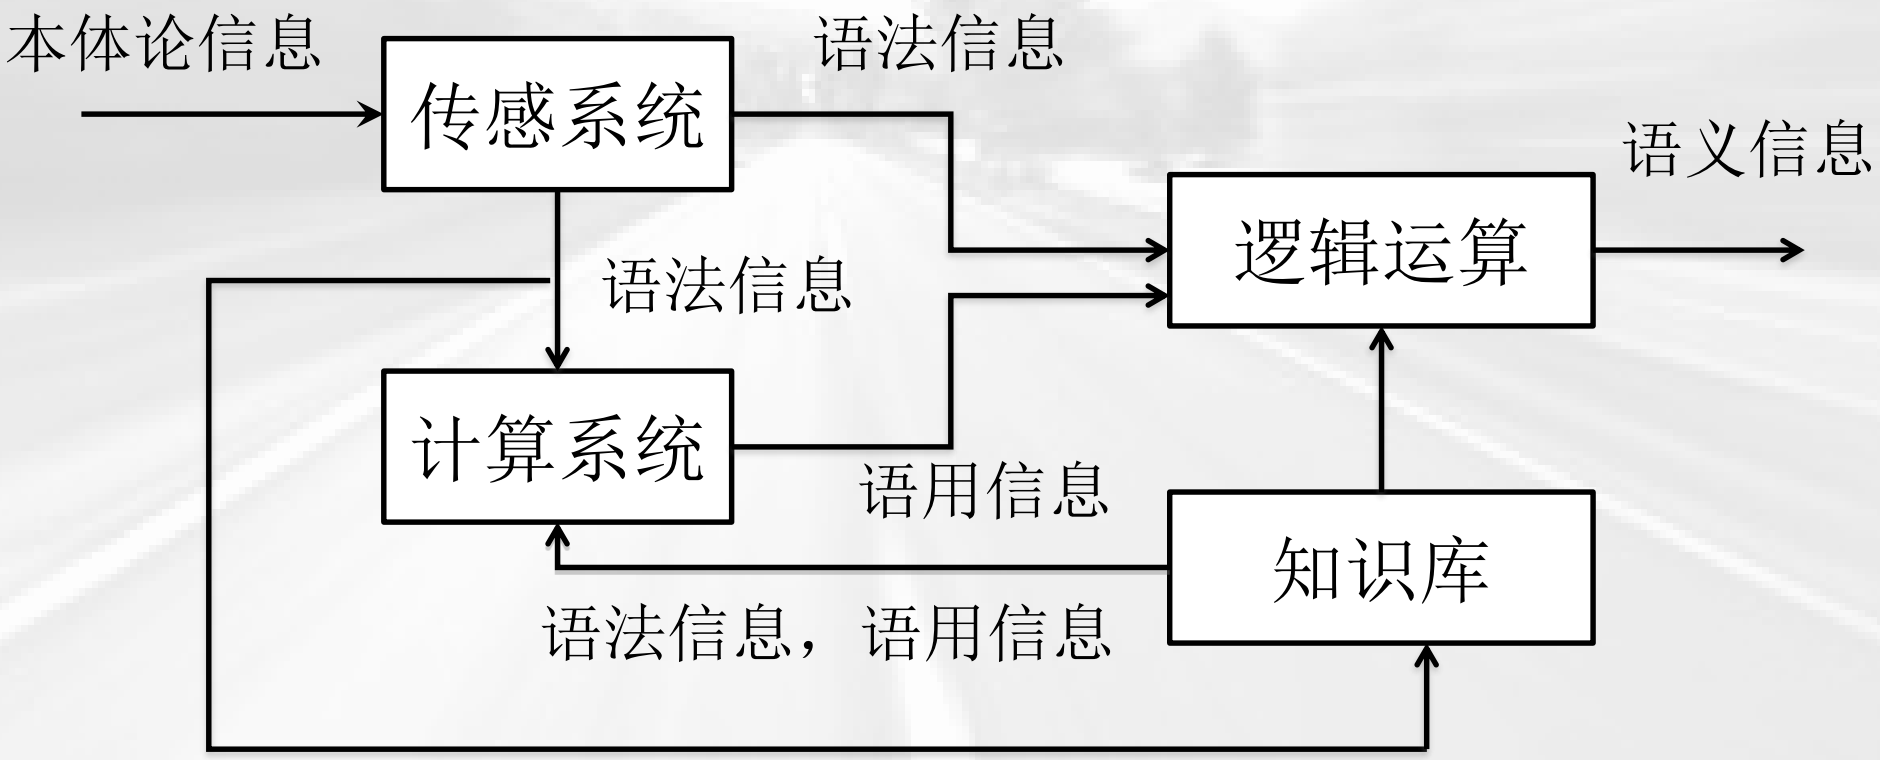

# 信息压缩（信源编码）

# 离散无记忆信源（DMS）的编码

- **离散无记忆信源：输出消息是独立的，不相关的，时间上和取值上都是离散的。**

- **目标：**在代价最小的意义上来最有效地表达一个信源。

包括量化、压缩、映射、变换、自然语言翻译等许多具体和抽象的过程。（**尽可能少的比特数来对信源输出进行描述**）

- 信源编码
  - 无损编码
    - 绝对无差错编码 $P_e^{(n)} = 0, \quad \forall n$
    - 渐进无差错编码 $P_e^{(n)} \xrightarrow{n\to\infty} 0$
  - 有损编码（限失真编码）

# 绝对无差错等长编码

## ★ 等长编码

Discrete Memoryless Source

◎ 一个离散无记忆信源DMS，长度为L，字符表个数为k:

$$\cdots U_1, U_2, U_3 \cdots U_L \cdots \qquad U_i \sim \begin{pmatrix} a_1 & a_2 & \cdots & a_K \\ p_1 & p_2 & \cdots & p_K \end{pmatrix}, \forall i$$

⊙ 一个编码符号集，字符个数为D，编码长度为N：

$$\boldsymbol{B} = \{b_1, b_2, \cdots, b_D\}$$

对源$U$的任意$L$长序列进行绝对无差错等长编码，则必有

$$D^N \geq K^L$$

那么就需要：

$$\boxed{N \geq \frac{L \log K}{\log D}}$$

如果D=2，那么：

$$N \geq L \log K$$

# 绝对无差错编码

## ⌘ 例1

| 十进制 | 二进制 | |
|---|---|---|
| 8 | 1000 | N=4 |
| 88 | 1011000 | N=7 |

- 十进制，K=10，信源长度L
- 二进制表示，D=2，编码长度N

如果L趋于无穷大，则每个十进制需用比特数趋于3.322个。

$N$ ³ log10 =3.322 ⟷ ? ⟷ H(U)=logK=3.322

两者有什么联系???...

# DMS的等长编码

## ⌘ 例2

⊙ 破获一起重大考试作弊团伙，经审讯发现他们无意中也运用了信源编码来提高效率：

1. 传统方法：

| 选择题 | ASCII |
| --- | --- |
| A | 01000001 |
| B | 01000010 |
| C | 01000011 |
| D | 01000100 |

N=8

2. 改进方法：

| 选择题 | 编码 |
| --- | --- |
| A | 00 |
| B | 01 |
| C | 10 |
| D | 11 |

N=2

$Log_2 4=2$

# DMS的不等长编码

## ⌘ 例2

⊙ 发现C出现的概率最大，A次之，经过调整后得到新方案：

3. 新改进方法：

| 选择题 | 概率 | 新编码 |
|---|---|---|
| A | 1/4 | 10 |
| B | 1/8 | 110 |
| C | 1/2 | 0 |
| D | 1/8 | 111 |

平均码长：$\bar{n}=2\times\frac{1}{4}+3\times\frac{1}{8}+1\times\frac{1}{2}+3\times\frac{1}{8}=\mathbf{1.75}$

信源的熵：$H(U)=\log 4\times\frac{1}{4}+\log 8\times\frac{1}{8}+\log 2\times\frac{1}{2}+\log 8\times\frac{1}{8}$

$=\mathbf{1.75}$

# DMS的不等长编码

## ⌘ 例2

⊙ 如果200个答案同时传出去，ABCD出现的次数严格按照概率比例：

4. 序贯传输：

| 选择题 | 概率 | 出现次数 | 编码 |
|---|---|---|---|
| A | 1/4 | 50 | 10 |
| B | 1/8 | 25 | 110 |
| C | 1/2 | 100 | 0 |
| D | 1/8 | 25 | 111 |

平均码长：$\bar{n}=(2\times 50+3\times 25+1\times 100+3\times 25)/200=\mathbf{1.75}$

L趋于无穷大：出现的概率接近信源概率。

# 绝对无差错等长编码

## ★ Shannon信源编码定理

- 如果十进制数字信源是等概率的，这时信源的熵=log10=3.322，为最大值；
- 如果不是等概率的，信源的熵有可能趋近于最大值；
- 平均码字长度N/L=H(U)。

即编码速率

$$\boxed{R \triangleq \frac{N \log D}{L} \geq \log K}$$

# 香农编码定理

- 熵为H(U)的离散无记忆信源，
- 信源输出长度为L, 编码符号有D；

$$\boxed{N \geq \frac{L \times H(U)}{\log D}}$$

这时，可以实现无损编码；

$$\boxed{N \leq \frac{L \times H(U)}{\log D}}$$

则不存在无损编码。

# 证明基础知识及回顾

信源U，输出一个长度为L的序列：

| | |
|---|---|
| $H(U)$ | $\{a_1,a_2,\ldots.a_k\}$ |
| 信源熵 | 变量A取值不确定性； |
| $H(u^L)$ | $\{A_1A_2\ldots.A_L\}$ |
| 信源序列熵 | 序列取值不确定性； |
| $H_L(U)$ | $\frac{1}{L}H(u^L)$ |
| 平均符号熵 | 序列中平均符号取值不确定性； |
| $H_\infty(U)$ | $\lim_{L\to\infty} H_L(U)$ |
| 熵速率 | L趋于无穷大的平均符号熵； |

# DMS编解码系统概念框图

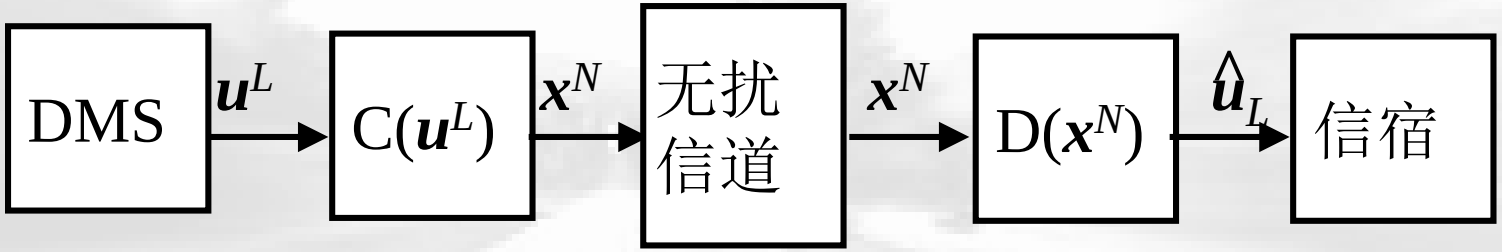


差错概率：

$$P_e = P\{\hat{u}^L \neq u^L\}$$

# 渐进无差错等长编码

$$H(U)=H(p_1,p_2,\cdots,p_k)=-\sum_{k=1}^{K}p_k\log p_k$$

$$R=\frac{N\log D}{L}\xrightarrow{?}H(U)$$

# AEP性质（I）

U为DMS，输出一个长度为L的序列：

$$\boldsymbol{u}^L = (u_1, u_2, \cdots, u_L),$$

无记忆：

$$p(\boldsymbol{u}^L) = \prod_{l=1}^{L} p(u_l)$$

自信息：

$$I(\boldsymbol{u}^L) = -\log p(\boldsymbol{u}^L) = \sum_{l=1}^{L} I(u_l)$$

平均每个符合的自信息：

$$\boxed{I_L \overset{\Delta}{=} \frac{I(\boldsymbol{u}^L)}{L} = \frac{1}{L}\sum_{l=1}^{L} I(u_l)}$$

# AEP性质（II）

由于平均自信息等于熵：

$$E(I_L) = E\{\frac{1}{L}\sum_{l=1}^{L} I(u_l)\} = E(I(u)) = H(U)$$

方差：

$$Var(I_L) = \frac{Var(I(u_l))}{L}$$

$$= \frac{1}{L}\sum_{i=1}^{K} \mathrm{P}(u_l = a_i)[-\log \mathrm{P}(u_l = a_i) - E(I(u_l))]^2$$

$$= \frac{1}{L}\sum_{i=1}^{K} p(a_i)[\log p(a_i) + H(U)]^2 \overset{\mathrm{D}}{=} \frac{s_I^2}{L}$$

# AEP性质（III）

由概率论中的契比雪夫不等式，对任何随机变量和任意正数，有

$$P\{|\xi - E(\xi)| > \varepsilon\} \le \frac{Var(\xi)}{\varepsilon^2}, \ \forall\text{随机变量}\xi\text{和}\varepsilon$$

可得

$$P\left\{\left|I_L - H(U)\right| > \varepsilon\right\} \le \frac{\sigma_I^2}{L\varepsilon^2}$$

给定$\varepsilon$，当$L$充分大时 $\dfrac{\sigma_I^2}{L\varepsilon^2} < \varepsilon$

故 $$\boxed{P\left\{\left|I_L - H(U)\right| > \varepsilon\right\} \le \varepsilon,}$$

或 $$\boxed{P\left\{\left|I_L - H(U)\right| < \varepsilon\right\} \ge 1 - \varepsilon.}$$

# AEP性质（II）

**契比雪夫不等式：** 设随机变量 $X$ 的期望 $EX=\mu$ 及方差 $DX=\sigma^2$ 存在，则对任意的 $\varepsilon>0$，有 $P\{|X-\mu|\geq\varepsilon\}\leq\dfrac{\sigma^2}{\varepsilon^2}$.

这就是著名的契比雪夫(Chebyshev)不等式

它有以下等价的形式：$P\{|X-\mu|<\varepsilon\}\geq 1-\dfrac{\sigma^2}{\varepsilon^2}$.

证明：设 $X$ 的概率密度为 $f(x)$，则有

$$P\{|X-\mu|\geq\varepsilon\}=\int_{|x-\mu|\geq\varepsilon}f(x)dx\leq\int_{|x-\mu|\geq\varepsilon}\frac{(x-\mu)^2}{\varepsilon^2}f(x)dx$$

$$\leq\int_{-\infty}^{+\infty}\frac{(x-\mu)^2}{\varepsilon^2}f(x)dx$$

$$=\frac{1}{\varepsilon^2}\int_{-\infty}^{+\infty}(x-\mu)^2f(x)dx$$

$$=\frac{\sigma^2}{\varepsilon^2}.$$

# AEP性质（III）

- 渐近等分性质(AEP)：当L充分大是，$I(u^L)/L$以概率1趋近于H(U)，即

$$\frac{1}{L}I(u^L)\rightarrow H(U)$$

# 典型列集合

令$H(U)$是为一个离散无记忆信源DMS$\{U，p(\cdot)\}$的熵，$\varepsilon$为任意正数，则称

$$A_{\varepsilon}^{(L)}(U)=\left\{\boldsymbol{u}^{\boldsymbol{L}}:\left|-\frac{1}{L}\log p(\boldsymbol{u}^{\boldsymbol{L}})-H(U)\right|<\varepsilon\right\}$$

为给定DMS输出长度为$L$的$\varepsilon$典型列集合，简称典型列集，其中$\boldsymbol{u}^{\boldsymbol{L}}\in U^{L}$。

**典型列性质（1）：**

当$L$足够大时，

$$\boxed{\mathrm{P}(\boldsymbol{u}^{L}\ \hat{\mathrm{I}}\ A_{e}^{(L)}(U))>1-e}$$

# 典型列性质

**典型列性质（2）：**

$$2^{-L[H(U)+\varepsilon]} \le p(\boldsymbol{u}^{\boldsymbol{L}}) \le 2^{-L[H(U)-\varepsilon]},\ \text{if}\ \boldsymbol{u}^{\boldsymbol{L}} \in A_{\varepsilon}^{(L)}(U)$$

**典型列性质（3）：**

$$(1-e)2^{L[H(U)-e]} \le \left|A_{e}^{(L)}(U)\right| \le 2^{L[H(U)+e]}$$

$$\boxed{\left|A_{e}^{(L)}(U)\right| \approx 2^{LH(U)}}$$

**证明：**

$$1 = \sum_{\boldsymbol{u}^{\boldsymbol{L}} \in U^{L}} p(\boldsymbol{u}^{\boldsymbol{L}}) \ge \sum_{\boldsymbol{u}^{\boldsymbol{L}} \in A_{\varepsilon}^{(L)}(U)} p(\boldsymbol{u}^{\boldsymbol{L}})$$

$$\ge \sum_{\boldsymbol{u}^{\boldsymbol{L}} \in A_{\varepsilon}^{(L)}(U)} 2^{-L[H(U)+\varepsilon]}$$

$$= \left|A_{\varepsilon}^{(L)}(U)\right| \cdot 2^{-L[H(U)+\varepsilon]}$$

$$\therefore \quad |A_{\varepsilon}^{(L)}(U)| \le 2^{L[H(U)+\varepsilon]}$$

$$1-\varepsilon \le \sum_{\boldsymbol{u}^{\boldsymbol{L}} \in A_{\varepsilon}^{(L)}(U)} p(\boldsymbol{u}^{\boldsymbol{L}})$$

$$\le \sum_{\boldsymbol{u}^{\boldsymbol{L}} \in A_{\varepsilon}^{(L)}(U)} 2^{-L[H(U)-\varepsilon]}$$

$$= |A_{\varepsilon}^{(L)}(U)|\, 2^{-L[H(U)-\varepsilon]}$$

$$\therefore \quad |A_{\varepsilon}^{(L)}(U)| \ge (1-\varepsilon)2^{L[H(U)-\varepsilon]}$$

# DMS编码定理

对熵为$H(U)$的离散无记忆信源所输出的$L$长序列进行等长编码，编码序列长为$N$，编码符号表包括$D$个可用编码符号。则当平均每信源符号所耗用的编码比特数（编码速率）$R \triangleq \dfrac{N\log D}{L}$满足

$$R > H(U) + \varepsilon_L$$

时，可实现渐进无差错的编码（$P_e^{(L)} \xrightarrow{L\to\infty} 0$）；

反之，若

$$R < H(U) - \varepsilon_L$$

则不可能实现无差错的编码。其中$\varepsilon_L$是满足$\varepsilon_L \xrightarrow{L\to\infty} 0$的正数。

# DMS编码定理的证明

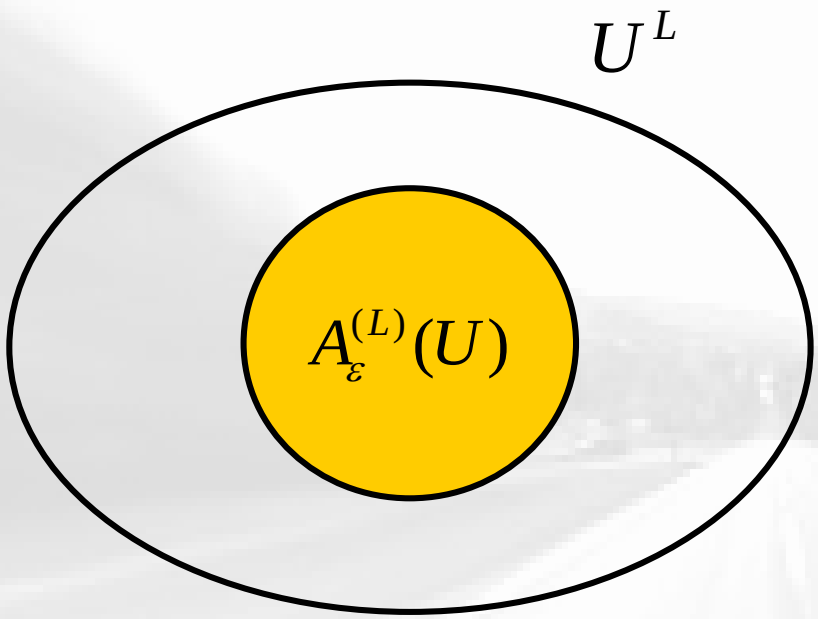


$$\left|U^L\right| = K^L$$

$$(1-\varepsilon)2^{L(H(U)-\varepsilon)} < \left|A_\varepsilon^{(L)}(U)\right| \le 2^{L(H(U)+\varepsilon)}$$

$$R > H(U) + \varepsilon$$

$$2^{LR} > 2^{L(H(U)+\varepsilon)} > \left|A_\varepsilon^{(L)}(U)\right|$$

$$\Pr\left(A_\varepsilon^{(L)}(U)\right) > 1-\varepsilon \Rightarrow P_e^{(L)} < \varepsilon$$

$$R = H(U) - \varepsilon' < H(U) - \varepsilon$$

$$\frac{2^{LR}}{\left|A_\varepsilon^{(L)}(U)\right|} < \frac{2^{L(H(U)-\varepsilon')}}{(1-\varepsilon)2^{L(H(U)-\varepsilon)}} = \frac{2^{L(\varepsilon-\varepsilon')}}{1-\varepsilon} \xrightarrow{L\to\infty} 0$$

# DMS的不等长编码

| 消息集 | 概率分布 | 码字 | 码长 |
|---|---|---|---|
| $a_1$ | $p_1$ | $b_{11}b_{12}\cdots b_{1n_1}$ | $n_1$ |
| $a_2$ | $p_2$ | $b_{21}b_{22}\cdots\cdots\cdots b_{2n_2}$ | $n_2$ |
| $\cdots$ | $\cdots$ | $\cdots$ | $\cdots$ |
| $a_K$ | $p_K$ | $b_{K1}b_{K2}\cdots\cdots b_{Kn_K}$ | $n_K$ |

$$\boxed{\bar{n} = \sum_{k=1}^{K} p_k n_k}$$

# 不等长码的例子

| 信源消息 | 出现概率 | 码A | 码B | 码C | 码D |
|---|---|---|---|---|---|
| $a_1$ | 0.5 | 0 | 0 | 0 | 0 |
| $a_2$ | 0.25 | 0 | 1 | 01 | 10 |
| $a_3$ | 0.125 | 1 | 00 | 011 | 110 |
| $a_4$ | 0.125 | 10 | 11 | 0111 | 1110 |

# 不等长码的基本要求

- 唯一可译性
- 即时可译性

$$B = \{101, 00110, 10111, 11001\}$$

$$10111, 00110, 11001, 101$$

$$101, 11001, 10110, 01101$$

# 唯一可译性

非奇异性

$$x_i \neq x_j \Rightarrow C(x_i) \neq C(x_j)$$

码扩展

$$C^*(x_1 x_2 x_3 \cdots x_n) = C(x_1)C(x_2)C(x_3)\cdots C(x_n)$$

**定义：**码的任意扩展都是非奇异的，则称码是唯一可译的。

# 唯一可译性的Sardinas&Patterson判据

后缀分解

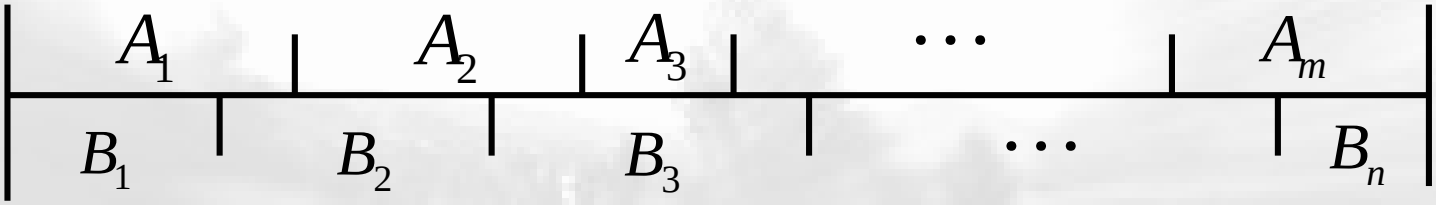


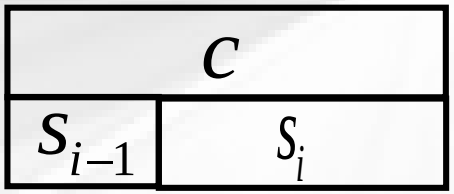


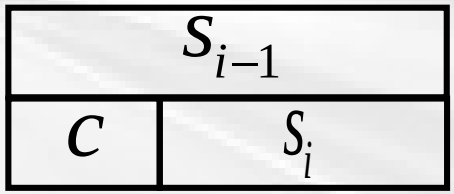


$$s_{i-1}s_i = c \qquad\qquad s_{i-1} = cs_i$$

$$S_0 = \mathbf{C}, s_i \hat{\mathrm{I}} \; S_i$$

# 后缀分解示例

| $S_0$=C | $S_1$ | $S_2$ | $S_3$ | $S_4$ | $S_5$ | … |
|---|---|---|---|---|---|---|
| 0 | 2 | 1 | 0 | 1 | 0 | … |
| 10 | | | 2 | 2 | 2 | … |
| 12 | | | 12 | | 12 | … |
| 21 | | | 122 | | 122 | … |
| 112 | | | | | 1 | … |
| 1122 | | | | | | … |

# Sardinas&Petterson判据

一个码是唯一可译码的充分必要条件是除$S_0$外没有任何一个后缀分解集中包含码字。

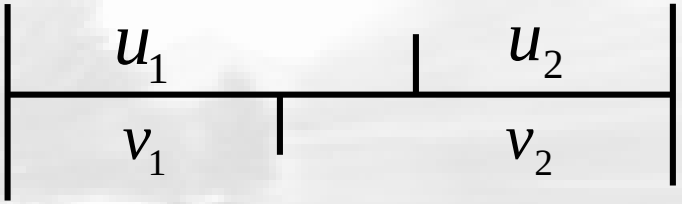


$$t = u_1 u_2 = v_1 v_2$$

$$\Rightarrow u_1 \neq v_1$$

不妨设$|u_1| > |v_1|$,则必有$u_1 = v_1 w$

$$\Rightarrow w u_2 = v_2$$

$$\Rightarrow S_2 \neq \Phi$$

若$S_1=\Phi$，则该码是即时可译并且唯一可译的。

# 异字头码

如果一个码中没有任何一个码字是其它码字的前缀，则称该码是异字头码，即$S_1=\Phi$。

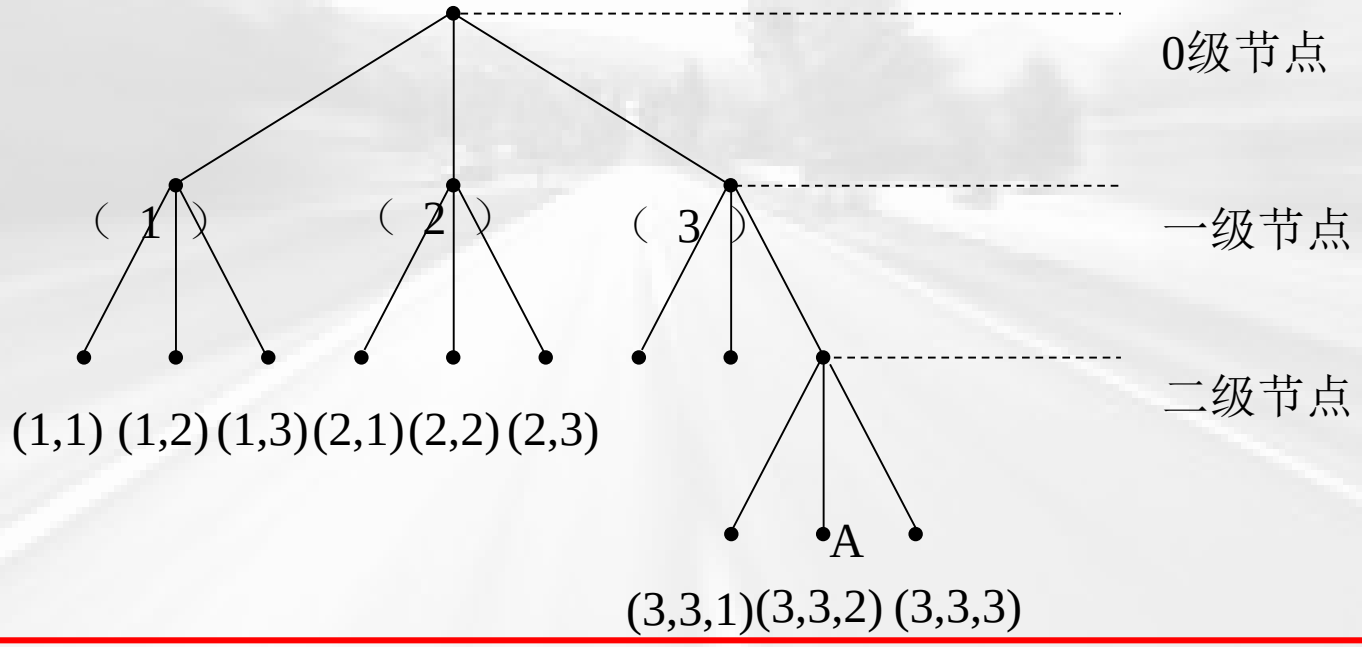


异字头码的树形表示：所有码字只出现在叶结点上

# Kraft不等式

存在长度为 $n_1, n_2, \cdots, n_K$ 的D元异字头码的充要条件为

$$\sum_{k=1}^{K} D^{-n_k} \le 1$$

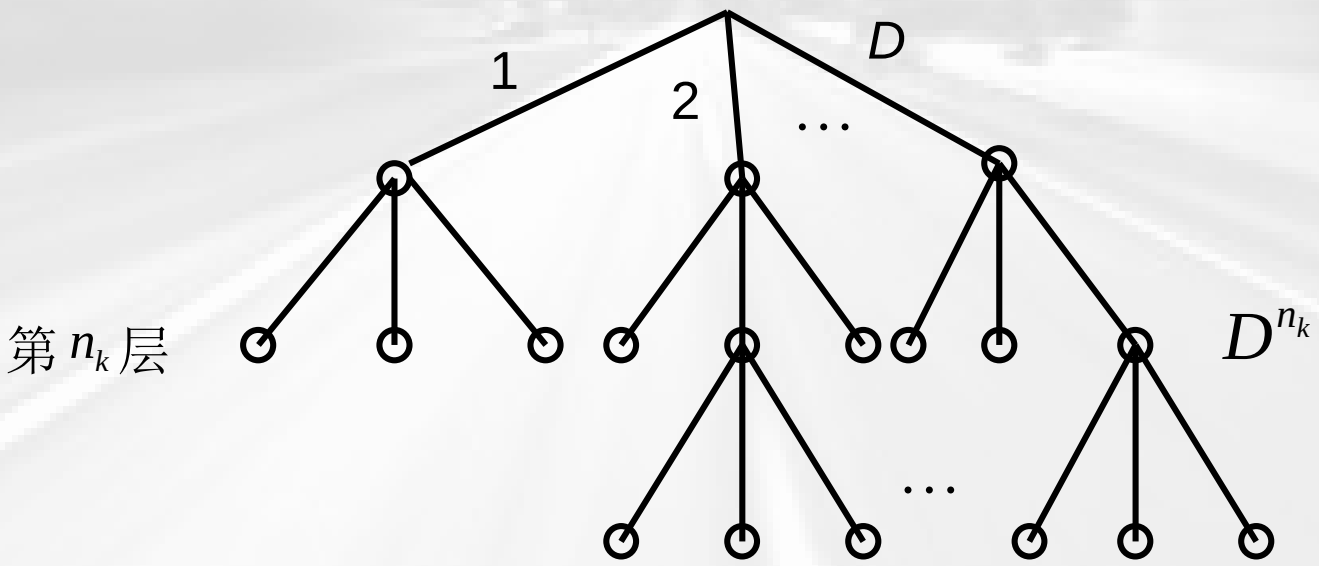

# Kraft不等式的证明

**必要性：**

设$n_1 < n_2 < \ldots < n_k$,可将异字头码的所有码字放置在码树的叶结点上，每放置一个长为$n_k$的码字，相当于砍掉其下生长的子树的共$D^{n_K-n_k}$个叶结点。为了保证放置过程可行，必须

$$\sum_{n_k=1}^{n_K} D^{n_K-n_k} \le D^{n_K}，即 \sum_{n_k=1}^{n_K} D^{-n_k} \le 1.$$

**充分性：**

可将所有码字依次放置在码树的叶节点上，方法如下：对长为$n_k$的码字在第$n_k$层任选一个可用的叶节点，砍掉其下生长的子树，相当于砍掉第$n_K$叶节点的$1/D^{n_k}$，如果$\sum_{n_k=1}^{n_K} D^{-n_k} \le 1$，则上述放置过程一直可以进行下去，即可以构成一个异字头码。.

# 唯一可译码与Kraft不等式

任何唯一可译码必然满足Kraft不等式。

证明：

$$\left(\sum_{k=1}^{K} D^{-n_k}\right)^r = \left(\sum_{k_1=1}^{K} D^{-n_{k_1}}\right)\left(\sum_{k_2=1}^{K} D^{-n_{k_2}}\right)\cdots\left(\sum_{k_r=1}^{K} D^{-n_{k_r}}\right)$$

$$= \sum_{k_1=1}^{K}\sum_{k_2=1}^{K}\cdots\sum_{k_r=1}^{K} D^{-(n_{k_1}+n_{k_2}+\cdots+n_{k_r})}$$

$r$个码字所构成的序列的长度

$$= \sum_{i=1}^{rn_{\max}} A_i D^{-i}$$

$A_i$表示由$r$个码字所组成的长度为$i$的序列的种数，则$i \le rn_{\max}$，其中$n_{\max} = \max\{n_1, n_2, \ldots, n_K\}$。

由唯一可译性 $\Rightarrow A_i \le D^i$

$$\sum_{k=1}^{K} D^{-n_k} \le \left(\sum_{i=1}^{rn_{\max}} 1\right)^{\frac{1}{r}} \le (rn_{\max})^{\frac{1}{r}} = 2^{\frac{1}{r}\log_2 rn_{\max}} \xrightarrow{r\to\infty} 1$$

# 唯一可译码与异字头码的关系

如果一个码是唯一可译

$\Rightarrow$ Kraft不等式成立

$\Rightarrow$ 存在一个具有同样长度的异字头码。

# 不等长编码定理

任何$D$元唯一可译码均满足：

$$\bar{n} \geq \frac{H(U)}{\log D};$$

一定存在一个$D$元唯一可译码，使得

$$\bar{n} \leq \frac{H(U)}{\log D} + 1$$

# 不等长编码定理的证明（I）

（1） $$H(U)-\bar{n}\log D=-\sum_{k=1}^{K}(p_k\log p_k+p_k n_k\cdot\log D)$$

$$=\sum_{k=1}^{K}p_k\log\frac{D^{-n_k}}{p_k}\le\sum_{k=1}^{K}p_k\left(\frac{D^{-n_k}}{p_k}-1\right)$$

$$=\left(\sum_{k=1}^{K}D^{-n_k}-1\right)\le 0$$

$$\therefore\ \bar{n}\ge\frac{H(U)}{\log D}$$

当且仅当$p_k=D^{-n_k}$，$k=1,2,\cdots,K$时，等号成立。

# 不等长编码定理的证明（II）

（2） 选择唯一的$n_k$，使得

$$D^{-n_k} \le p_k < D^{-(n_k-1)}, k = 1, 2, \cdots, K$$

对左边不等式两侧求和，得

$$\sum_{k=1}^{K} D^{-n_k} \le \sum_{k=1}^{K} p_k = 1$$

故存在长度为$n_1, n_2, \cdots, n_K$的异字头码。

对右侧不等式取对数并求期望值，得

$$\sum_{k=1}^{K} p_k \log p_k < -\sum_{k=1}^{K} p_k (n_k - 1) \log D$$

$$H(U) > \bar{n} \log D - \log D$$

# 不等长编码定理的扩展

对长为$L$的平稳遍历源$U^L$,有

$$\frac{H(U^L)}{\log D} \le \bar{n}(U^L) < \frac{H(U^L)}{\log D} + 1$$

故

$$\frac{H(U^L)}{L\log D} \le \bar{n} = \frac{\bar{n}(U^L)}{L} < \frac{H(U^L)}{L\log D} + \frac{1}{L}$$

进一步，若源离散无记忆，有

$$\frac{H(U)}{\log D} \le \bar{n} < \frac{H(U)}{\log D} + \frac{1}{L}$$

编码速率：$R \triangleq \bar{n}\log D$, 则

$$H(U) \le R \le H(U) + \log D / L$$

对DMS，$R \xrightarrow{L\to\infty} H(U)$

编码效率：$\eta = \dfrac{H(U)}{R}$

# 授课小结

- 信源编码的基本概念（编码速率等）
- AEP性质
- DMS等长编码定理
- 不等长编码的概念
- 唯一可译性与Kraft不等式
- DMS不等长编码定理

# 作业

- 复习授课内容
- 预习3.3节
- 独立完成习题（每章交一次）
  - 3.1
  - 3.2（选做）
  - 3.3
  - 3.4

# 最佳不等长编码（Huffman编码）

**最佳不等长码：**给定信源分布，在平均码长最短的意义上最佳

**二元最佳码：**

给定信源分布，其最佳二元编码必然满足：

1）其出现概率越小的消息所对应的码长越长；

2）出现概率最小的两个消息所对应的码长相 等，且其码字最后一位不同

# 最佳不等长编码（Huffman编码）

1） $\boxed{p_1 \geq p_2 \geq \cdots \geq p_K \Rightarrow n_1 \leq n_2 \leq \cdots \leq n_K}$

| | | | |
|---|---|---|---|
| $a_1$ | $p_1$ | $\boxed{b_{11}b_{12}\cdots b_{1n_1}}$ | $n_1$ |
| $a_2$ | $p_2$ | $\boxed{b_{21}b_{22}\cdots\cdots b_{2n_2}}$ | $n_2$ |
| $\cdots$ | $\cdots$ | $\cdots$ | $\cdots$ |
| $a_K$ | $p_K$ | $\boxed{b_{K1}b_{K2}\cdots\cdots b_{Kn_K}}$ | $n_K$ |

# 最佳不等长编码（Huffman编码）

2） $\boxed{n_{K-1} = n_K}$

| | | | |
|---|---|---|---|
| $a_1$ | $p_1$ | | $n_1$ |
| $a_2$ | $p_2$ | | $n_2$ |
| … | … | … | … |
| $a_{K-1}$ | $p_{K-1}$ | | $n_{K-1}$ |
| $a_K$ | $p_K$ | | $n_K$ |

# 最佳不等长编码（Huffman编码）

3） $\boxed{\text{对}a_{K-1}\text{和}a_K\text{,有}b_{K-1,n_{K-1}} \neq b_{K,n_K}}$

| | | | |
|---|---|---|---|
| $a_1$ | $p_1$ | | $n_1$ |
| $a_2$ | $p_2$ | | $n_2$ |
| $\cdots$ | $\cdots$ | $\cdots$ | $\cdots$ |
| $a_{K-1}$ | $p_{K-1}$ | | $n_{K-1}$ |
| $a_K$ | $p_K$ | | $n_K$ |

# 辅助源

$$U \sim \begin{pmatrix} a_1 & a_2 & \cdots & a_{K-1} & a_K \\ p_1 & \geq p_2 & \cdots & \geq p_{K-1} & \geq p_K \end{pmatrix}$$

$$U' \sim \begin{pmatrix} a_1' = a_1 & a_2' = a_2 & \cdots & a_{K-1}' = a_{K-1} \cup a_K \\ p_1' = p_1 & p_2' = p_2 & \cdots & p_{K-1}' = p_{K-1} + p_K \end{pmatrix}$$

# 可递归编码原理

对辅助源U'的最佳编码也是对原始源的最佳编码。

若 $C'_1, C'_2, \cdots, C'_{K-1}$ 是辅助源 $U'$ 的最佳编码，相应码长分别为 $n'_1, n'_2, \cdots, n'_{K-1}$.

对应地，$U$ 的码字 $C_1, C_2, \cdots, C_K$ 的长度分别为

$$n_k = n'_k \qquad k = 1, 2, \cdots, K-2$$

$$n_k = n'_{K-1} + 1 \qquad k = K-1, K$$

故：

$$\begin{aligned}\overline{n} &= \sum_{k=1}^{K} p_k \cdot n_k \\ &= \sum_{k=1}^{K-2} p_k n'_k + (p_{K-1} + p_K)(n'_{K-1} + 1) \\ &= \overline{n'} + (p_K + p_{K-1})\end{aligned}$$

所以由 $\overline{n'}$ 最小可得出 $\overline{n}$ 也是最小。

# Huffman编码

$$U=\begin{pmatrix} a_1 & a_2 & a_3 & a_4 & a_5 & a_6 & a_7 & a_8 \\ 0.2 & 0.19 & 0.18 & 0.17 & 0.15 & 0.1 & 0.007 & 0.003 \end{pmatrix}$$

$$H(U)=2.617\text{比特}/\text{符号}$$

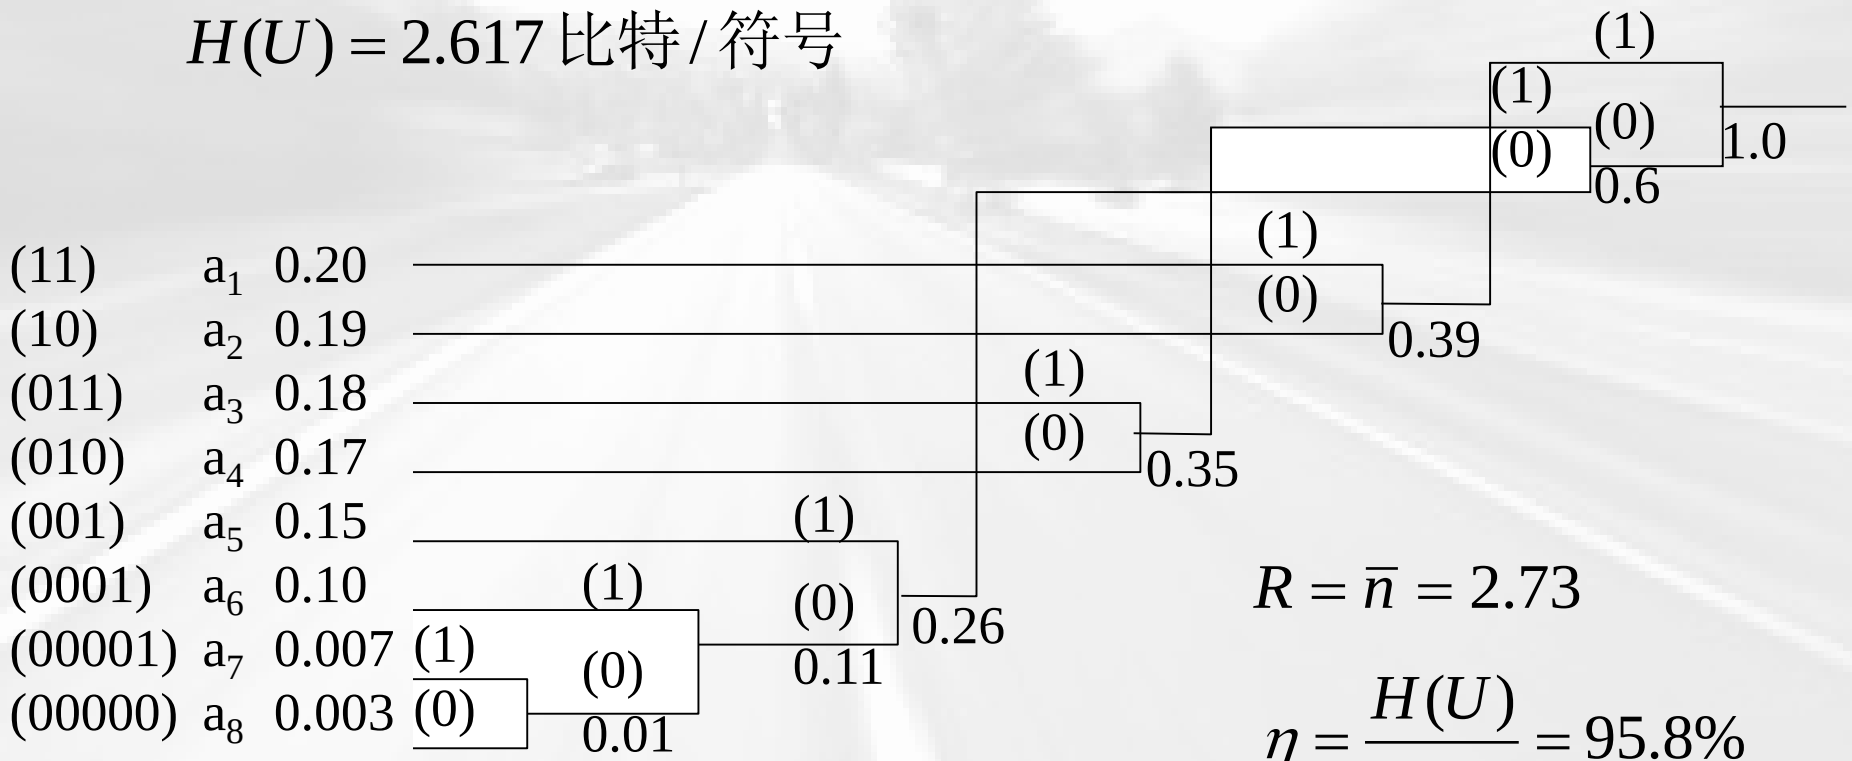


$$R=\bar{n}=2.73$$

$$\eta=\frac{H(U)}{R}=95.8\%$$

# D元Huffman编码的虚拟消息合并

若$K=(D-1)\cdot i+1$,则每次均有$D$个消息要合并，短标号得到充分利用；

若$K=(D-1)\cdot i+M$,则必须增补$D-M$个概率为零的虚拟消息，使得最后一次合并仍有$D$个消息要合并，从而充分利用短标号。

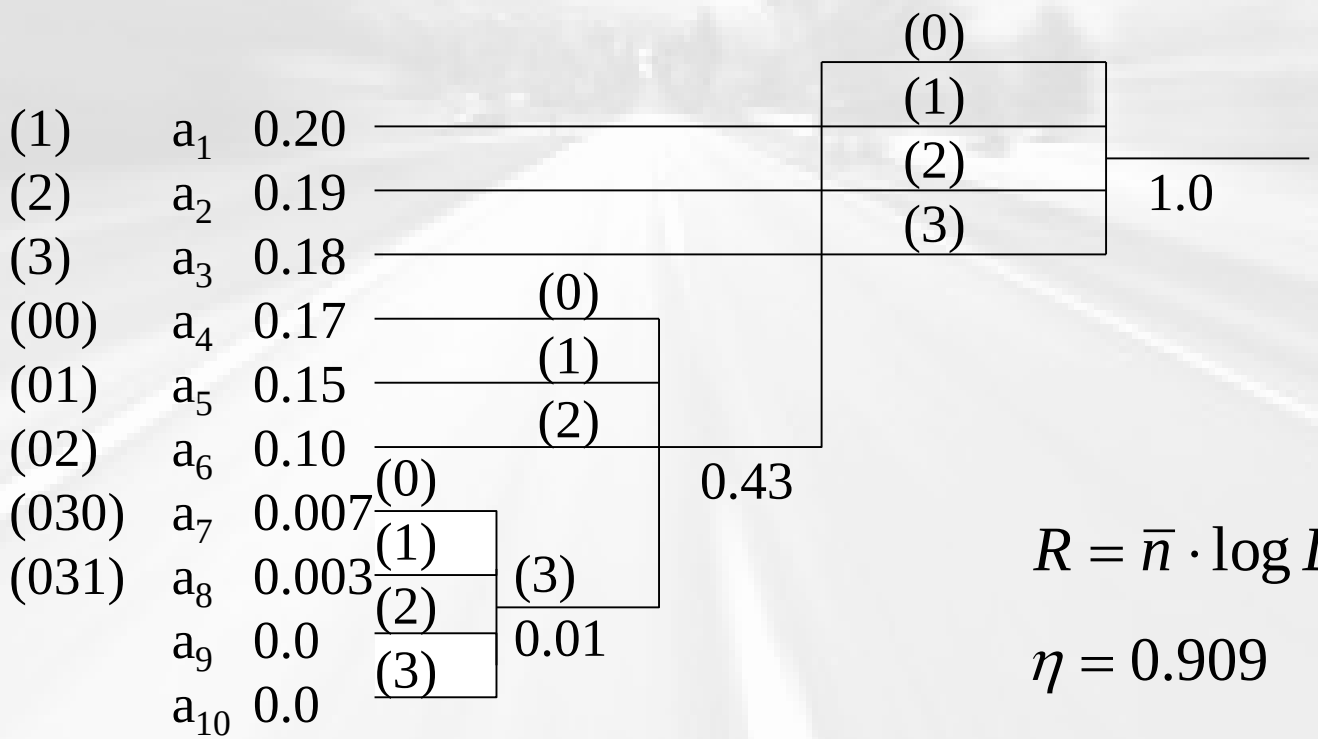


$$R=\bar{n}\cdot\log D=2.88$$

$$\eta=0.909$$

思考题：如何进一步增加编码效率？

# 授课小结

- 唯一可译性与Kraft不等式
- DMS不等长编码定理
- 最优不等长编码（Huffman编码）

# 作业

- 复习授课内容
- 预习3.3节
- 独立完成习题（每章交一次）
  - 3.6
  - 3.7
  - 3.9
  - 3.10
  - 3.12

# Shannon编码

$$U \sim \begin{pmatrix} a_1 & a_2 & \cdots & a_{K-1} & a_K \\ p_1 & \geq p_2 & \cdots & \geq p_{K-1} & \geq p_K \end{pmatrix}$$

$$P_k = \sum_{i=1}^{k-1} p_i \qquad P_0 = 0$$

$$= 0.\underbrace{c_1 c_2 \cdots c_{l_k-1} c_{l_k}} c_{l_k+1} \cdots$$

$$l_k = \left\lceil \log \frac{1}{p_k} \right\rceil \qquad 2^{-l_k} \leq p_k < 2^{-l_k+1}$$

# Shannon编码

香农编码示意表

| 信源符号 $a_i$ | 符号概率 $p_i$ | 累加概率 $P_k$ | $-\log P_k$ | 码长 $l_i$ | 码字 |
|---|---|---|---|---|---|
| $a_1$ | 0.20 | 0 | 2.34 | 3 | 000 |
| $a_2$ | 0.19 | 0.2 | 2.41 | 3 | 001 |
| $a_3$ | 0.18 | 0.39 | 2.48 | 3 | 011 |
| $a_4$ | 0.17 | 0.57 | 2.56 | 3 | 100 |
| $a_5$ | 0.15 | 0.74 | 2.74 | 3 | 101 |
| $a_6$ | 0.10 | 0.89 | 3.34 | 4 | 1110 |
| $a_7$ | 0.01 | 0.99 | 6.66 | 7 | 1111110 |

# Shannon编码的异字头性

设$i < j$，则$l_i < l_j$。

$$P_i = 0.\underbrace{c_1^{(i)} c_2^{(i)} \cdots c_{l_i-1}^{(i)} c_{l_i}^{(i)}}_{l_i} c_{l_i+1}^{(i)} \cdots \qquad P_j = 0.\underbrace{c_1^{(j)} c_2^{(j)} \cdots c_{l_j-1}^{(j)} c_{l_j}^{(j)}}_{l_j} c_{l_j+1}^{(j)} \cdots$$

若码字$i$是码字$j$的前缀，则必有：

$$P_j - P_i \le 0.00\cdots 0 c_{l_i+1}^{(j)} c_{l_i+2}^{(j)} \cdots c_{l_j}^{(j)} \cdots < 2^{-l_i}$$

然而，

$$P_j - P_i = \sum_{m=1}^{j\text{-}1} p_m - \sum_{m=1}^{i\text{-}1} p_m = p_i + p_{i+1} + \cdots p_{j-1} \ge p_i \ge 2^{-l_i}$$

# Shannon编码的效率

$$H(U) \le \bar{n} = \sum_{k=1}^{N} l_k p_k = \sum_{k=1}^{N} \left\lceil \log \frac{1}{p_k} \right\rceil p_k < H(U) + 1$$

- 与Huffman码相比，Shannon码渐进收敛性能较差，但具有竞争最优性

比如：p1=0.9999, p2=0.0001

# Fano编码

$$U=\left(\begin{array}{cccc|ccc} a_1 & a_2 & \cdots & a_k & a_{k+1} & \cdots & a_K \\ p_1 \geq & p_2 \geq & \cdots & p_k \geq & p_{k+1} \geq & \cdots & \geq p_K \end{array}\right)$$

概率和对分法

$$\left|\sum_{i=1}^{k} p_i - \sum_{i=k+1}^{K} p_i\right| \to \min$$

# Fano编码的效率

$$U=\begin{pmatrix} a_1 & a_2 & a_3 & a_4 & a_5 & a_6 \\ 0.3 & 0.25 & 0.2 & 0.15 & 0.05 & 0.05 \end{pmatrix}$$

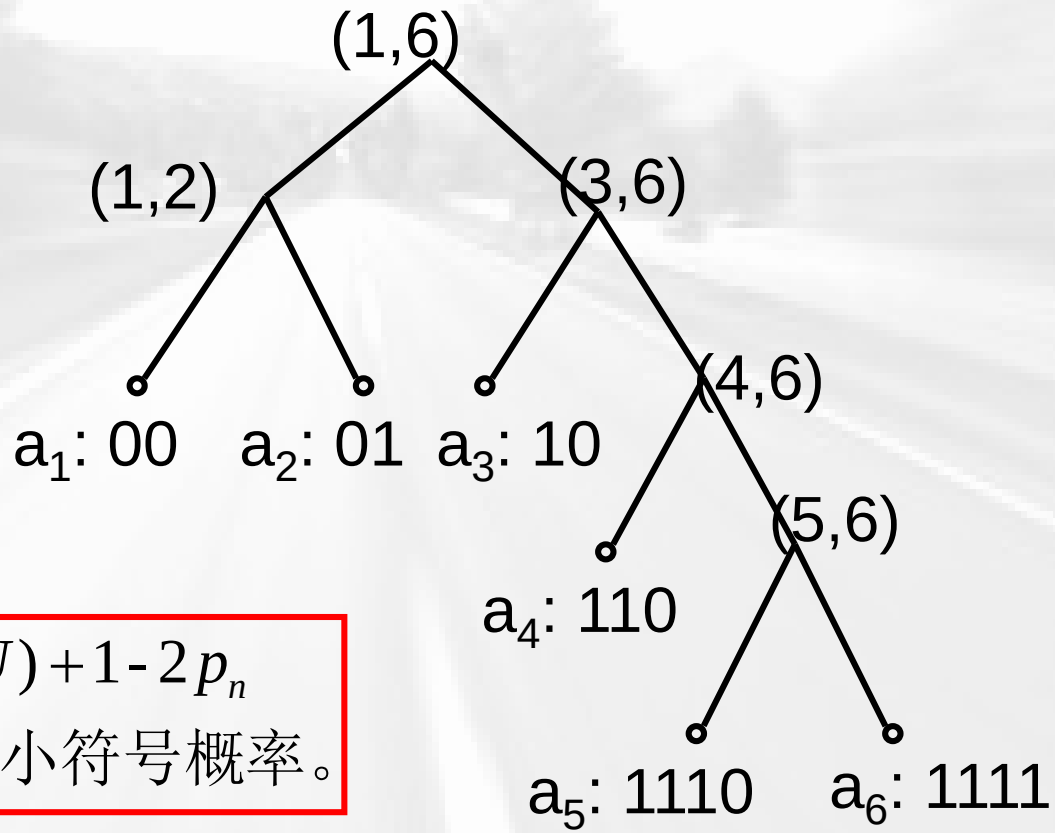


$$\bar{n} \le H(U)+1-2p_n$$

其中$p_n$为最小符号概率。

# Shannon-Fano-Elias编码

$$U = \begin{pmatrix} a_1 & a_2 & \cdots & a_m \\ p(1) & p(2) & \cdots & p(m) \end{pmatrix}$$

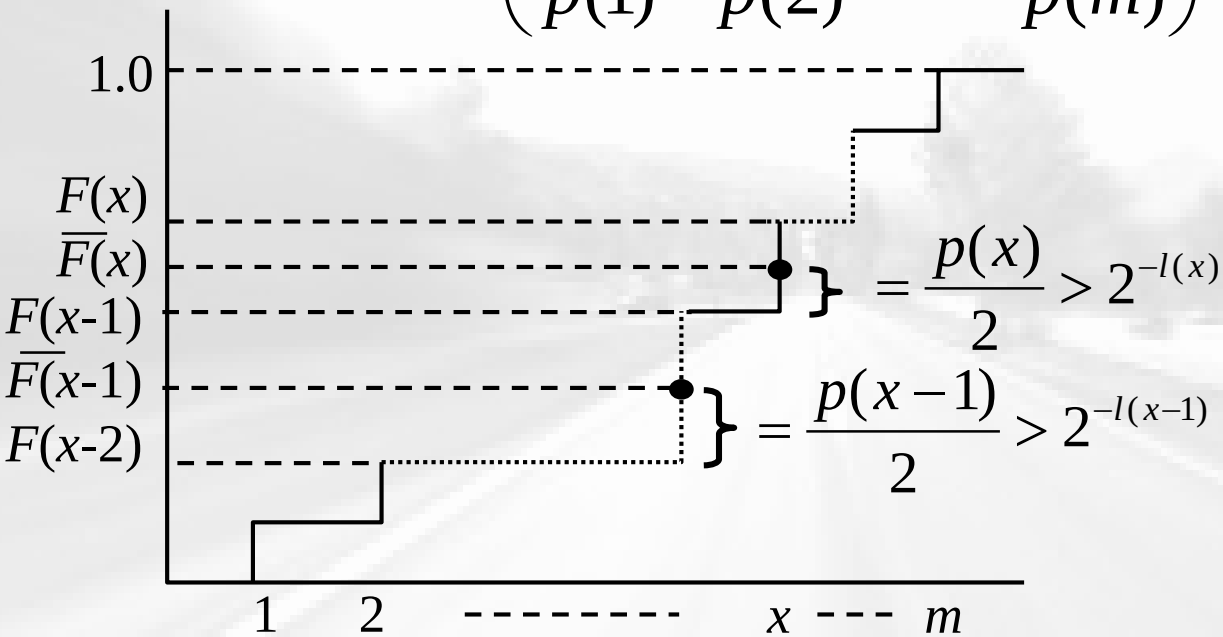


$$\bar{F}(x) \overset{\Delta}{=} \sum_{i<x} p(i) + \frac{1}{2} p(x)$$

$$F(x) \overset{\Delta}{=} \sum_{i \le x} p(i)$$

$$l(x) = \left\lceil \log \frac{1}{p(x)} \right\rceil + 1$$

$$\bar{F}(x) - \bar{F}(x-1) > \bar{F}(x) - F(x-1) = \frac{p(x)}{2} > 2^{-l(x)}$$

$$[\bar{F}(x)]_{l(x)} = 0.z_1 z_2 z_3 \cdots z_{l(x)}$$

$$\bar{F}(x) - \left[\bar{F}(x)\right]_{l(x)} < 2^{-l(x)}$$

# S-F-E编码的效率

$$\bar{n} = \sum_x p(x)l(x) = \sum_x p(x)\left\{\left\lceil \log\frac{1}{p(x)} \right\rceil + 1\right\} < H(U) + 2$$

| $x$ | $p(x)$ | $F(x)$ | $\bar{F}(x)$ | $\bar{F}(x)$的二进表示 | $l(x)$ | 码字 | Huffman码 |
|---|---|---|---|---|---|---|---|
| 1 | 0.25 | 0.25 | 0.125 | 0.001 | 3 | 001 | 01 |
| 2 | 0.5 | 0.75 | 0.5 | 0.10 | 2 | 10 | 1 |
| 3 | 0.125 | 0.875 | 0.8125 | 0.1101 | 4 | 1101 | 001 |
| 4 | 0.125 | 1.0 | 0.9375 | 0.1111 | 4 | 1111 | 000 |

# 算术编码

- ✧熵编码的效率
- ✧熵编码的概率排序
- ✧序贯编码

**基本思想：**

S-F-E编码的直接推广（从单个符号到*n*长序列）

**关键之处：**

累积概率 $F(x^n)$和 $\overline{F}(x^n)$ 的快速有效的迭代算法

# 算术编码的基本算法（I）

定义：$x^n = x_1 x_2 \cdots x_n > y^n = y_1 y_2 \cdots y_n$是指$\sum_i x_i \cdot 2^{-i} > \sum_i y_i \cdot 2^{-i}$.

$$F(x^n) \overset{\Delta}{=} \sum_{y^n < x^n} p(y^n)$$

$$\overline{F}(x^n) \overset{\Delta}{=} F(x^n) + \frac{1}{2} p(x^n)$$

$$C(x^n) = \left[\overline{F}(x^n)\right]_{l(x^n)}$$

$$l(x^n) = \left\lceil \log \frac{1}{p(x^n)} \right\rceil + 1$$

# 算术编码的基本算法（II）

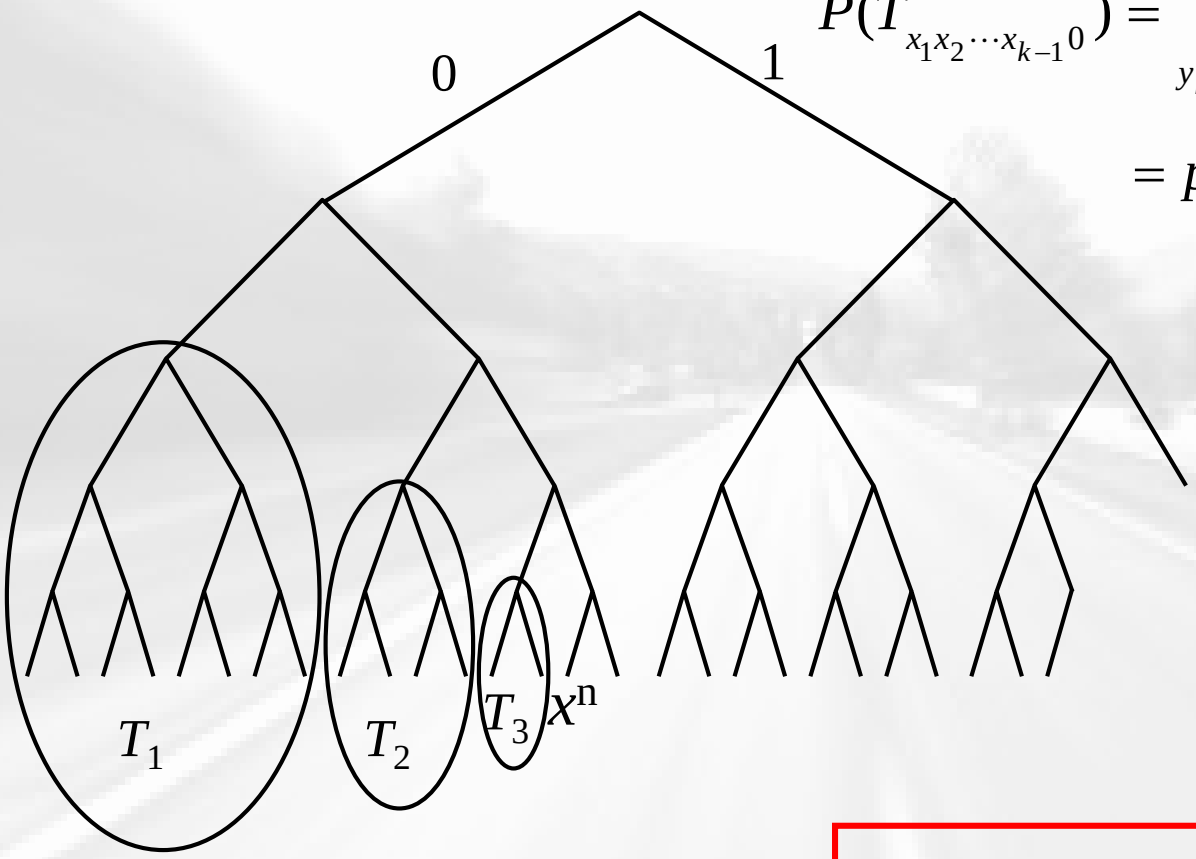


$$P(T_{x_1x_2\cdots x_{k-1}0}) = \sum_{y_{k+1}\cdots y_n} p(x_1x_2\cdots x_{k-1}0y_{k+1}\cdots y_n)$$

$$= p(x_1x_2\cdots x_{k-1}0)$$

$$F(x^n) = \sum_{y^n<x^n} p(y^n)$$

$$= \sum_{T:\text{在}x^n\text{左边的子树}T} P(T)$$

$$= \sum_{x_k=1} P(x_1x_2\cdots x_{k-1}0)$$

$$p(x^{n+1}) = p(x^n x_{n+1}) = p(x^n)p(x_{n+1})$$

$$F(x^{n+1}) = F(x^n x_{n+1}) = \begin{cases} F(x^n) & x_{n+1}=0 \\ F(x^n)+p(x^n0) & x_{n+1}=1 \end{cases}$$

# 算术编码的基本算法（II）

## ★ 例子

- 对于树图，若二元消息x=1的概率为θ，x=0的概率为1-θ，则对$x^n$=(01110),有：

$$F(01110) = P(T_1) + P(T_2) + P(T_3)$$
$$= p(00) + p(010) + p(0110)$$
$$= (1-q)^2 + q(1-q)^2 + q^2(1-q)^2$$

# 通用信源编码

- 适用于具有任何统计特性的信源的有效编码方法

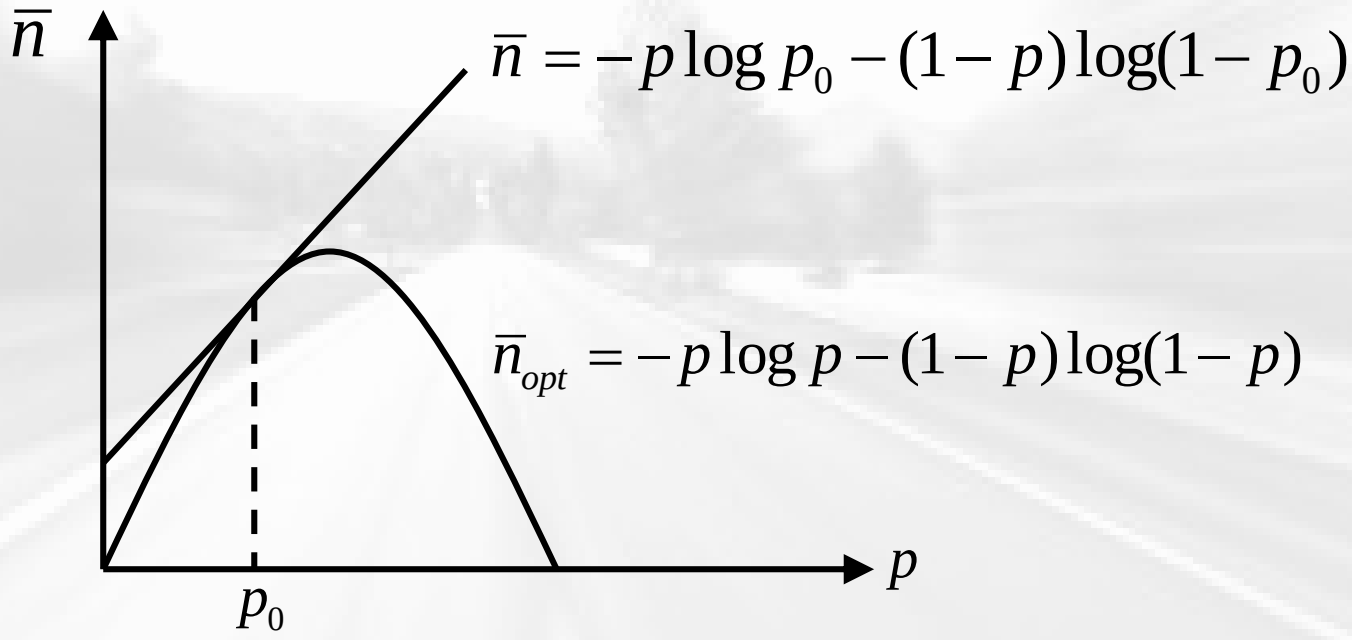


Shannon编码在不能准确获得信源分布时的性能恶化

# Z-L编码

- 序列的相异分解

1 | 0 | 1 1 | 0 1 | 0 1 0 | 0 0 | 1 0 | …

$$\{(\log C(n), b(n))\}$$

{(000,1), (000, 0), (001, 1), (010, 1), (100, 0), (010, 0), (001, 0)…}

# 平稳信源的编码

令$\varepsilon$是任意小正数，对平稳有记忆信源$\{U^L, p(u^L)\}$进行不等长$D$元编码，则总可以找到一个$L(\varepsilon)$，当$L > L(\varepsilon)$时，平均编码码长$\bar{n}$满足

$$\frac{H(U|U^\infty)}{\log D} \le \bar{n} < \frac{H(U|U^\infty)}{\log D} + \varepsilon$$

# 马尔科夫源的编码

对于各态经历的平稳马尔可夫信源，直接利用平稳源不等长编码定理可得

$$\frac{H_\infty(U)}{\log D} \le \bar{n} < \frac{H_\infty(U)}{\log D} + \frac{1}{L}$$

$$H_\infty(U) = \lim_{L\to\infty} \frac{1}{L} H(U_1, \cdots, U_L) = \sum_{s\in S} q(S=s) H(U \mid S=s)$$

$$= H(U \mid S)$$

# 马尔科夫源的编码示例（I）

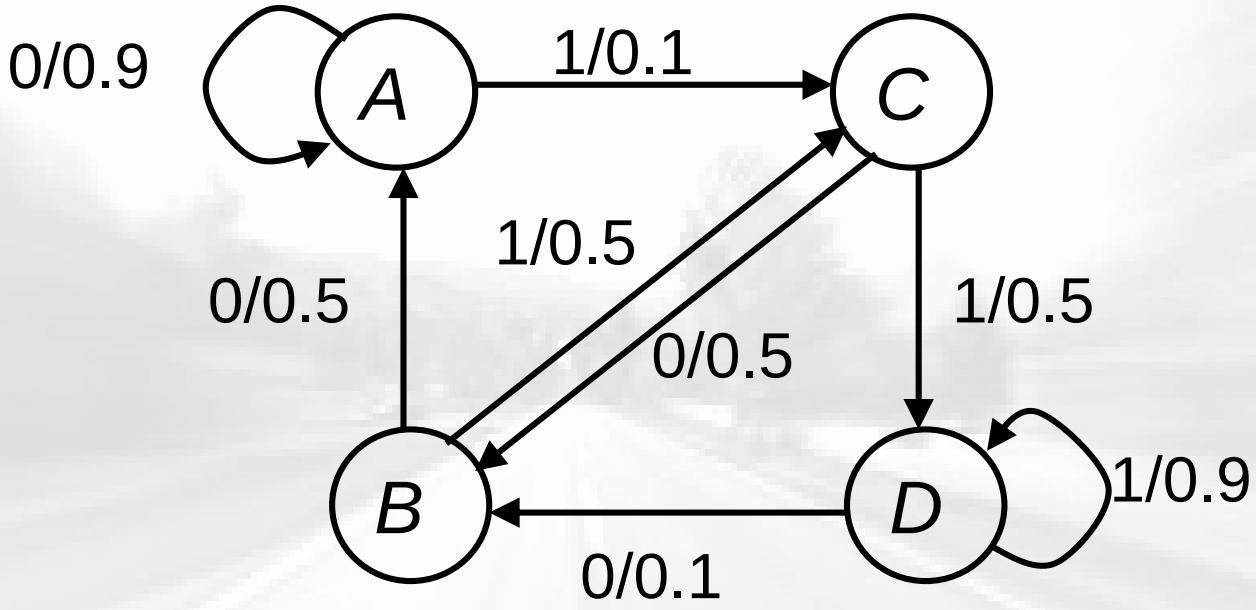


$$q(A)=q(D)=5/12,\ q(B)=q(C)=1/12$$

$$H(X\mid S=A)=H(X\mid S=D)=0.469$$

$$H(X\mid S=C)=H(X\mid S=B)=1$$

$$\therefore H(X\mid S)=\sum_{s\in\{A,B,C,D\}}q(s)H(X\mid s)=0.558$$

$\therefore$ 二元编码时

$$\bar{n}_{opt}=H_{\infty}/\log 2=H(X\mid S)=0.558$$

# 马尔科夫源的编码示例（II）

对上述马尔科夫源输出的单符号序列进行二元编码，则：

任何状态下均至少需要1比特来标记该输出符号，因此平均编码码长 。

$$\bar{n} = 1$$

# 马尔科夫源的编码示例（III）

对上述马尔科夫源输出的二符号序列进行二元编码，则：

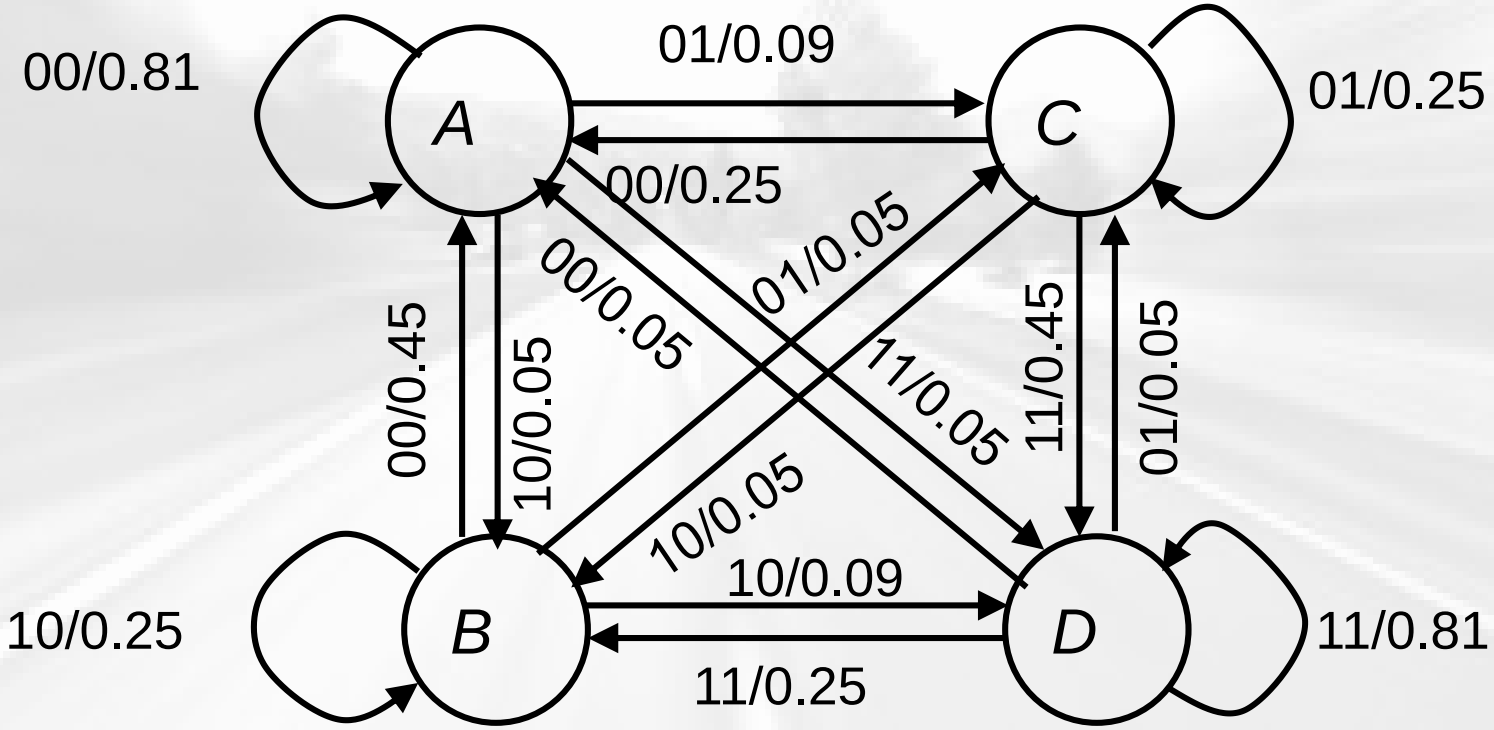

# 马尔科夫源的编码示例（IV）

| 消息 | *A* | *B* | *C* | *D* |
|---|---|---|---|---|
| 00 | 0(0.81) | 0(0.45) | 10(0.25) | 111(0.05) |
| 01 | 10(0.09) | 111(0.05) | 110(0.25) | 110(0.05) |
| 10 | 110(0.05) | 110(0.25) | 111(0.05) | 10(0.09) |
| 11 | 111(0.05) | 10(0.25) | 0(0.45) | 0(0.81) |
| 平均码长 $\bar{n}_L$ | 1.29 | 1.85 | 1.85 | 1.29 |

$$\bar{n} = \frac{1}{L}(q(A)\times 1.29 + q(B)\times 1.85 + q(C)\times 1.29 + q(D)\times 1.29) = 0.6917$$

# 授课小结

- Shannon编码
- Fano编码
- S-F-E编码
- 算术编码
- 通用信源编码
- 平稳源编码
- 马尔科夫信源编码

# 作业

- 复习授课内容
- 预习第四章
- 独立完成习题（下次上课交作业）
  - 3.14
  - 3.15
  - 3.16

# 课堂测验二



- **题一**

  假设变量X，Y服从某联合分布。根据AEP性质，在Y的i.i.d观察序列 $\mathbf{Y}^n$ 已知的情况下，所有可能的 $\mathbf{X}^n$ 序列中大约包含多少个典型列？用变量X，Y的熵或者其条件熵表示。

- **题二**

  判断下列码的唯一可译性和即时可译性：

  {10，110，1001，0110}

- **题三**

  用不超过3句话简述马尔可夫信源编码的实现过程。

# 谢谢大家!